

本科生短学期实习报告

MLB 投手数据分析与港科大 IEDA 暑研

姓名 杨炎新 学号 3230102355

接收单位 上海思搏动态智能科技有限公司

指导教师 陈发动 实践时间 2026 年暑期

实践概况与主要成果

本次短学期实践以棒球数据分析课程项目为主体，接收单位为上海思搏动态智能科技有限公司。同期，我在香港科技大学工业工程与决策分析系跟随 Sinian 教授完成了一个多月的大模型对齐暑研。报告围绕这两项实际工作，说明我如何确定问题、整理数据、修正判断并形成结果。MLB 项目承担课程的数据分析任务；暑研补充了理论推导、计算实验和学术汇报方面的训练。

MLB 项目选择今井达也进入美国职业棒球大联盟后的调整问题。分析冻结至 2026 年 8 月 12 日，覆盖 17 场比赛、288 个打席及 1,240 个带球种标签的投球。结果提示，优先处理的问题是保送和打席早期的球数控制；滑球仍可作为主要球种，对左打的四缝线与低速第三球种值得重点检查。两次牛棚登板只有 23 个打席，因此建议采用短期校准和逐步增加负荷的办法，保留重新评估先发角色的空间。

港科暑研提出 Prospective Reward Modeling，即根据奖励模型对下游策略的影响来评价和训练奖励模型。研究完成了 RLHF 与 DPO 基础学习、局部策略遗憾推导、HPC4 合成机制实验和最终答辩。冻结实验包含三个随机种子、八条策略流程，共 73,728 条重新生成的回答。结果支持继续研究奖励拟合与策略效用之间的差异，同时也保留了小样本、合成偏好和局部单步更新的适用范围。

两项任务给我的共同训练，是把研究问题落实到可检查的对象上。棒球分析需要回答球队下一步可以观察什么；暑研需要回答奖励训练后策略实际发生了什么变化。只汇总已有数据，或只报告训练损失，都不足以把这两个问题说明白。

在 MLB 项目中，我借助生成式工具完成资料整理、代码实现和文稿修改，并将原始数据、脚本、提示记录与结果一起留存。数字的依据仍是公开数据及处理结果。港科暑研则以本人学习笔记、阶段汇报、实验报告与答辩材料为记录。下文分别说明任务进展和判断依据。

研究问题与分析假设

这次数据分析作业中，我选择今井达也适应 MLB 的表现作为研究对象。最初吸引我的是一个容易产生分歧的问题：一名投手在原有联赛取得较好成绩，进入新联赛后结果波动，应当先调整技术、配球还是比赛角色？如果报告只列出防御率和球速变化，读者仍然不知道下一步应该检查什么。我因此把题目收窄为“今井达也下一阶段应优先调整哪些环节，以及在什么条件下重新提高先发负荷”。

在计算分组指标前，我先写下几种可能的解释：制造三振和挥空的能力下降；进区不足带来保送；四缝线与滑球使用过于集中；对左、右打者的方案不够均衡；先发任务长度影响执行。它们分别对应球速与挥空、Zone%与首球好球率、球种结构、打者侧别和面对打线轮次。这样安排后，每张表都有要回答的问题，也能检查某种直觉是否受到相反证据的挑战。

待检验解释	重点检查	需要保留的相反证据
球威普遍下降	三振、挥空、四缝线球速	三项未同步走低，则不先归因于球威
球数控制不足	进区、首球好球、保送	若过程改善而失分不降，另查接触质量
球种配套不足	滑球价值、第三球种速度层	高使用率本身不代表应削减核心球种
侧别或任务长度影响	左右打、角色、打线轮次	差异不稳或区间宽，不作永久角色判断

表 1 研究假设与核查方法

我尤其希望避免由最终结果倒推原因。ERA 偏高可能同时受到保送、长打、守备和失分顺序影响；转入牛棚后的好表现，也可能与日期、恢复情况和对手有关。为了让分析能够推进，我把问题分为三个层次：先确认发生了哪些变化，再比较哪些解释更符合数据，最后提出下一批数据应该观察的内容。建议的作用是帮助安排后续检验，而不是声称已经找到唯一原因。

这一题目也让我体会到，数据分析的困难往往出现在计算之前。研究范围太大，任何结果都能被塞进结论；问题太窄，又容易只解释一个漂亮的数字。最后形成的研究框架保留了五条检查线，但把报告中心放在控球、球种衔接和角色恢复顺序上。作为学生项目，我能完成的是公开数据整理、证据比较和方案设计；实际训练中的动作调整、健康判断与比赛安排，仍需要教练和医疗人员掌握的内部信息。

数据来源与冻结范围

我将主分析窗口固定为 2026 年 3 月 29 日至 8 月 12 日，覆盖今井达也 17 场 MLB 比赛，其中 15 次先发、2 次牛棚出场。对应样本为 288 个打席、64.2 局。这里的 64.2 是棒球记分法，表示 64 局加 2 个出局数，计算时需要换成 194 个出局数，不能直接按小数处理。原始文件于 8 月 14 日下载，报告中的截止日始终指比赛窗口，避免把下载日期混作数据日期。

不同来源承担不同任务。MLB StatsAPI 提供比赛日志，用来核对角色、局数、面对打者数、三振和保送；Baseball Savant 的 Statcast 逐球记录用于球种、球数、位置、挥棒和打者侧别分析。Savant 的 Expected Statistics 提供 xERA，Pitch Arsenal 用于核对球种使用和官方 Run Value 等汇总指标。新闻材料只帮助确认适应过程和角色变化的时间背景，不参与效果计算。

来源	主要用途
MLB StatsAPI	比赛日志、角色、出局数、三振及保送
Baseball Savant	逐球、球种、挥棒、xERA 与官方球种价值
NPB 官方及 NPB Basement	职业历史与 NPB 球种结构参照
MLB.com 报道	补充角色改变的时间背景

表 2 主要来源与分析用途

跨联盟部分采用 NPB 官方传统统计，以及第三方网站 NPB Basement 保存的高级投球和球种数据。它们帮助我了解今井原有的球种使用习惯，尤其是第三球种是否具有持续使用的历史。不过，两套联盟数据的比赛环境、追踪方法和球种标签并不完全一致。我没有把 NPB 的 xPV/100 与 MLB 的 Run Value/100 直接相减，也没有把同名标签当成完全相同的投球。

整理时，我为 17 份原始快照保留了来源网址、下载时间、文件大小和 SHA-256，原始文件与处理结果分开保存。这样做最直接的好处是：复核某个数字时，能够回到当时实际使用的文件，而不必重新打开可能已经更新的网页。17 份快照中，部分是计算输入，部分用于生成 NPB 处理表，其余用于背景说明和人工核查；我在记录中写明了这些差别。冻结数据使本次报告的结论有了明确的适用范围，也为以后比较新旧窗口留下了基础。

数据清洗与指标口径

逐球文件共有 1,241 条记录，其中一条是没有球种标签的自动坏球事件。我保留了原始记录，球种和逐球主分析使用其余 1,240 球。该事件出现在一个打席的第 7 球，不影响 288 个打席的首球记录。三振、保送和面对打者数继续以比赛日志为准，没有从删去该行的逐球表倒推。最终将带标签投球数、三振数、保送数和比赛数与官方参考逐项核对，四项差值均为 0。

这一步让我明确了比赛、打席和投球三个分析单位。场次与先发角色按比赛判断；K%、BB%以打席为分母；球种使用率、Zone%等以投球为单位。80 次三振对应 27.8%的 K%，42 次保送对应 14.6%的 BB%，两者之差为 13.2%。同样是百分比，如果混用分母，就可能在表格看似整齐的情况下得出错误比较。

指标	本窗口分子与分母	结果
三振率	80 次三振 ÷ 288 打席	27.8%
保送率	42 次保送 ÷ 288 打席	14.6%
进区率	541 个区内球 ÷ 1,240 球	43.6%
首球好球率	149 个好球结果 ÷ 288 个打席首球	51.7%
挥空率	175 次挥空 ÷ 542 次挥棒	32.3%
追打率	190 次区外挥棒 ÷ 699 个区外球	27.2%

表 3 主要过程指标及实际分母

我把关键指标的事件定义固定在代码中。Zone%按 Statcast 的 zone 字段 1—9 计为进区，本样本为 541/1,240，即 43.6%；首球好球率为 149/288，即 51.7%。Whiff%按仓库与 Savant 导出一致的挥空事件集合计算，为 175 次挥空除以 542 次挥棒，得到 32.3%。Chase%的分母则是 699 个有效区外投球，190 次区外挥棒对应 27.2%。这些指标分别描述进区、打席开局、挥棒落空和追打，不能互相替代。

在分组时，我使用日志确定先发或牛棚，用打者站位区分左、右打，并保留投球前球数及面对打线轮次。对样本较小的比例，除点估计外补充 Wilson 置信区间；变速球只有 29 球、8 次挥棒，因此直接展示计数。清洗完成并不表示解释已经正确，但清楚的定义使错误更容易被发现。后来核对报告时，我能顺着一个比例找到分子、分母和原始字段，这比只保存最终图表可靠得多。

控球表现与调整优先级

冻结窗口内，今井的 ERA 为 5.29，xERA 为 4.89，赛季结果确实不理想。但继续查看过程指标后，我没有发现三振、挥空和四缝线球速同步下降。MLB 的 K%为 27.8%，数值上与 NPB 2025 年相同；Whiff%为 32.3%；四缝线均速 94.86 mph，与 NPB 2025 年的 94.87 mph 接近。联盟环境不同，这些数字不能证明能力完全未变，却足以使我放弃把问题笼统归结为球速或挥空能力下降。

更明显的变化发生在保送。BB%由 NPB 2025 年的 7.0%上升至 MLB 窗口内的 14.6%，K-BB%从 20.7%降至 13.2%。同时，Zone%只有 43.6%，首球好球率为 51.7%。这些数字放在一起看，表现出一种值得优先处理的矛盾：投手仍然能够让打者挥空，却不容易在打席早期建立有利球数。三振并没有抵消过多的免费上垒，深球数也会增加完成每个打席的成本。




图 1 三振率保持接近而保送率上升 跨联盟数值仅作历史参照

我随后加入 Chase%作为补充检查。27.2%的追打率没有显示打者正在异常积极地追逐区外球，因此不能寄希望于坏球自然获得更多挥棒。由此，报告把调整顺序放在可控进区和首球执行上，而没有提出继续追求额外球速。这一顺序来自多个指标相互印证，而不是单独看到某一项低于平均后作出的判断。

在写建议时，我还区分了“进区”和“投到好位置”。Zone%提高并不必然意味着投球质量提高，如果更多球落在容易被击中的区域，结果可能更差。因此，我将 Zone%、首球好球率和 BB%作为需要持续观察的过程指标，同时保留位置与接触质量的核查要求。公开数据能够指出优先检查的环节，却不能判断一次偏离目标来自控球、配球意图还是动作变化。这也使我在报告中更加重视提出可复核的问题，而不是给出缺乏依据的动作处方。

球种结构与打者侧别

今井在 MLB 主要使用滑球和四缝线，两者使用率分别为 45.3%和 43.5%，合计 88.9%。最初看到这种集中度，我考虑过是否应该降低滑球比例；进一步检查后，滑球 40.6%的 Whiff%和+4 的官方 Run Value 说明，它仍是当前表现较好的球种。我因此把思路调整为保留已有优势，再寻找第三球种能够补充的位置，而不是仅凭使用率高就要求减少滑球。

变速球的变化提供了一条具体线索。NPB 2025 年同名标签使用率为 12.7%，MLB 降至 2.3%；均速由 84.7 升至 86.8 mph，与四缝线的速度差由约 10.1 缩至 8.0 mph。但 MLB 仅有 29 球，62.5%的 Whiff%实际上来自 8 次挥棒中的 5 次。我没有据此断言该球种有效，而是把问题改成：原来低速第三球种的作用，能否在新环境下重新建立？

为核对是否只是标签变化，我又将 CH 与 FS 相关标签合并比较，使用占比由 NPB 的 17.0%降至 MLB 的 5.7%。这只能说明公开标签中低速非滑球层的占比收缩，不能证明两边每一球的握法与移动相同。这个补充检查保留了结构变化的方向，也使报告措辞更加准确。

按左、右打拆分后，四缝线的差异更值得关注。对左打 311 球，Whiff%为 15.4%，RV/100 为-1.27；对右打 229 球，相应为 27.0%和+1.47。两组挥空比例的区间存在重叠，且尚未控制球数、落点与对手，所以我把它用来确定核查重点：优先检查对左打的四缝线位置和第三球种衔接。对右打则暂时保留四缝线与滑球的主轴。这一分析把“配球需要改变”的宽泛意见收窄成了可继续收集数据的问题。

四缝线分组	投球数	挥空率	投手 RV/100
对左打	311	15.4%	-1.27
对右打	229	27.0%	+1.47

表 4 四缝线面对不同侧别打者的样本内结果

后续验证需要同时记录“投了多少”和“投成什么样”。第三球种比例增加后，若速度层恢复，却更频繁落入容易被击中的位置，就不能仅凭挥空率宣布调整有效。对左打四缝线也应继续按球数和落点分组，检查差异是否集中在特定情境。这两项检查都需要新样本；现有公开数据只能帮助选择试验方向，不能代替训练中的逐球反馈。

先发牛棚与打线轮次

角色比较是本项目最容易得出过强结论的部分。15 次先发对应 1,151 球、265 个打席，两次牛棚只有 89 球、23 个打席。先发的 Zone%、首球好球率和 Whiff% 分别为 43.4%、49.8% 和 31.6%，牛棚中提高到 46.1%、73.9% 和 40.0%。单看表格，很容易认为转入牛棚已经解决了问题；但其中首球好球率的明显变化，只来自 23 个打席，单次结果就会使比例产生较大波动。

我因此为角色比较补充了 Wilson 95% 置信区间。Zone%、首球好球率、Whiff% 和 Chase% 四组先发与牛棚区间全部重叠，提示目前估计仍不稳定。角色变化又与比赛日期、伤后恢复、对手和使用方式同时发生，无法从公开样本中分离各自的作用。更具体地说，牛棚数据支持继续观察这种使用方式，但还不足以决定永久角色。




图2 先发与牛棚的过程指标 牛棚估计区间较宽

球速检查也改变了一个容易接受的解释。四缝线均速在先发时为 94.87 mph，牛棚为 94.72 mph，并没有随任务缩短而上升。我据此没有采用“转牛棚释放球速”的叙述。随后查看面对打线第三轮的 161 球，四缝线球速没有明显下降，投手视角逐球 Run Value 合计仍为正，这同样不支持“第三轮必然失效”的简单判断。

这些结果使我重新理解了小样本的用途。它可以帮助选择下一步值得检验的方向，也能反驳与现有数据明显不符的说法，但不能承担稳定能力评估的全部责任。我的最终建议把多局牛棚视为一个短期观察环境，在保持比赛强度的同时，集中记录首球、进区和第三球种表现。是否增加先发负荷，则留给扩大样本和后续阶段来判断。这样既没有忽略已有的积极信号，也避免用两次出场代替长期证据。

调整步骤与评估条件

在完成诊断后，我将建议整理为校准、过程观察、负荷递增和角色评估四个阶段。这是一份基于公开资料的分析方案，用来说明如何把证据转成后续观察安排，并非已经在球队中实施的训练计划。第一阶段建议设置约 3—4 周的多局牛棚校准期，集中检查四缝线进区、滑球坏球质量，以及第三球种的速度层和接触质量。健康情况需要先由相应专业人员评估。

第二阶段先积累至少 60 个打席，此后统一使用最近 60 个打席的滚动窗口。暂定同时满足 Zone%不低于 46%、首球好球率不低于 60%、BB%不高于 10%，且健康稳定时，才进入增加负荷的阶段。如果其中一项未达，继续观察；如果 BB%超过 12%，或 Zone%与首球好球率同时低于目标，则回到校准阶段重新检查。这些数值是为了固定判断规则，并不是由 23 个牛棚打席估计出的能力分界，也没有经过未来样本验证。

步骤	观察标准	处理方式
初始校准	3—4 周多局牛棚；先完成至少 60 打席	优先检查健康、进区、首球与对左打配套
过程观察	滚动 60 打席：进区 $\geq 46\%$ 、首球 $\geq 60\%$ 、保送 $\leq 10\%$	任一缺项不升级；保送 $> 12\%$ 或前两项同时缺项，回校准
负荷增加	45、60、75 球；每级至少两次	条件未满足维持；负荷相关退化退一级；健康异常先复查
角色评估	完成 75 球阶段，各级至少两次且过程稳定	再评估传统先发或短先发安排

表 5 依据冻结分析提出的阶段安排

第三阶段按 45、60、75 球逐级增加负荷，每一级至少观察两次。除总表现外，比较前后半段的进区、首球、四缝线球速和第三球种速度差。升级条件尚未满足时停留在当前水平；只有当前负荷下出现后半段执行或球速恶化时，才考虑退回一级；若控球明显回落，则重新校准。完成 75 球阶段后，再根据扩大样本中的稳定性讨论传统先发、短先发或跟随投手等安排。

写出退回条件，是这次方案整理中对我帮助很大的一步。只有目标而没有维持与退回规则，分析就容易随着单场结果来回改变。反过来，任何阈值也都不应该压过实际健康信息。疼痛、明显疲劳或动作异常出现时，统计达标不能成为继续增加负荷的理由。报告最终强调的不是某个固定比例一定最优，而是让每次判断都有同一窗口、明确指标和下一步可检查的内容。

复现整理与判断修订

完成分析后，我将来源快照、处理表、图表、报告源文和脚本整理到 MLB-Analytics 仓库。原始文件保留下载记录与哈希，处理结果按总览、球种、侧别、球数、角色和轮次分开保存。主要分析能够通过冻结数据重新运行，测试与对账记录用于检查核心数字。这样，读者既可以先看两页汇总，也可以沿着具体表格找到计算规则和原始来源。

保留内容	复核时的用途
data/raw/ 与来源清单	确认当时下载了什么、来自哪里、是否改变
data/processed/ 分组表	核对分子分母、球种和角色样本
scripts/ 与 tests/	按固定口径重算，并检查关键统计关系
qa/ 对账记录	确认比赛数、投球数、三振及保送闭合

表 6 主要归档内容与复核用途

整理过程中，我发现“能够运行”与“全部自动更新”并不是同一件事。当前主分析直接读取 4 份 MLB 原始文件，并使用已经冻结的 NPB 处理表；17 份快照并非都在每次计算中重新加工。刷新数据后，报告中的静态文字也不会自动同步。因此，新窗口需要先检查下载范围和字段，再重算指标、比较变化，最后逐项修改正文与图注。我把这些实际限制写进复现说明，避免后来使用者误以为一条命令就能生成完全更新的报告。

研究记录也按真实的工作阶段整理：提出问题并保存首批来源，完成首轮分析，补充来源说明与报告，建立离线流程，再进行交付检查。同一次分析中的多个发现没有被写成多轮独立实验。对我而言，保留判断怎样变化，比把过程描述得复杂更有价值。例如，高滑球占比不再被直接视为问题，第三球种从“新增开发”改为“核查原有功能”，牛棚从角色答案改为短期观察环境，这些调整都有对应的数据原因。

这次项目使我形成了更具体的数据分析习惯：先写问题和相反条件，再统一来源与分母，之后用分组结果缩小问题，最后说明下一批数据会如何改变建议。我也认识到，复现解决的是别人能否按同样规则得到同样数字，不能替代对解释是否合理的判断。报告的价值在于把一组比赛结果整理成可以讨论、可以检查、也可以继续修正的分析，而不是把不确定的情况写成一个确定答案。

港科暑研的起点与阶段汇报

进入港科大 IEDA 暑研后，我首先补齐 RLHF 和 DPO 的基础。RLHF 通常先用成对偏好训练奖励模型，再用奖励指导策略优化；DPO 则通过策略与参考策略的概率比直接构造偏好学习目标。我阅读相关论文时，重点记录两种方法分别依赖哪些假设，以及奖励模型、策略表示能力不足时，评价结果会怎样改变。

7 月 14 日的阶段汇报按 RLHF 与 DPO、统计分析、采样设计和个人想法展开。准备这次汇报的作用，是迫使我把文献中的概念放到同一套符号下：哪些误差来自偏好数据，哪些来自模型类别限制，哪些又会真正影响最终策略。下图保留了当时的幻灯片总览，展示的是选题形成时的问题线索。



图3 第一周阶段汇报总览与基础学习手稿

我的研究直觉来自数据驱动运筹学中的 Smart Predict then Optimize。预测更准确，并不必然带来更好的优化决策。迁移到大模型对齐后，我把问题写成：奖励模型在偏好标签上拟合得更好，是否一定会让更新后的策略获得更高效用？如果存在不一致，就应研究哪些奖励误差会改变策略，而不是对所有函数误差作相同处理。

在导师指导下，我将这一想法逐步明确为 Prospective Reward Modeling。这里的重点是提前考虑奖励模型将如何影响后续策略更新。第一周的阅读与汇报因此成为后续推导的起点，而不是与实验割裂的一份文献总结。

从奖励拟合到策略效用

第二周，我围绕奖励模型的下游效用展开推导。给定奖励函数，先求它在参考策略和 KL 约束下诱导的策略；再用目标奖励评价这一策略。这样，训练奖励与评价奖励承担不同角色，研究对象也从标签拟合误差转向了策略选择的后果。




图 4 第二周 Prospective Reward Modeling 早期推导笔记

$$Reg(r) = U(r^*) - U(r)$$

我把策略遗憾定义为目标奖励下可达最优策略的效用，减去候选奖励所诱导策略的效用。这个差值对应一个直接的问题：由于奖励模型的选择，最终策略损失了多少效用？若两个奖励函数虽然数值不同，却诱导相同策略，那么它们在这个评价标准下不应被区分。

完整求解需要反复训练策略，计算代价很高。因此，我在参考策略附近作二阶展开，用 Fisher 矩阵刻画策略移动的代价，用奖励与策略得分函数之间的一阶矩刻画更新方向。局部策略遗憾由两个奖励在这些方向上的差异决定；不影响当前策略更新的奖励分量不会进入该局部目标。

这一结论使“预测优化一体化”的类比有了具体内容：奖励模型应优先拟合策略能够感知、且会影响效用的部分。局部近似依赖参考点与小步更新，不能直接替代任意强度的完整强化学习。明确这一范围后，暑研实验采用受限策略空间和单步更新，先检查机制能否出现。

从手写推导到 HPC4 实验

手写推导进一步把局部目标改写为成对数据能够估计的形式。一个提示下的回答提供节点统计，两个回答的比较提供差分统计。两者分别进入策略几何和奖励方向的计算，必须保留相同的回答索引和偏好方向，不能仅凭矩阵维度相同就认为实现正确。

实验环节	固定设置
奖励模型	冻结 1,536 维表示，仅训练无偏置线性头
策略空间	最后一层 <code>q_proj</code> 与 <code>v_proj</code> 的 rank-4 LoRA-B
策略更新	$\beta=0.2$ ；单步自然梯度
比较信号	O 为精确合成奖励差；H 为重复模拟偏好标签
评价样本	每策略 512 个正式测试提示，各重新生成 6 个回答

表 7 暑研机制实验的主要控制条件

第三周，我在 HPC4 上完成合成机制实验的初步实现。参考模型采用 Qwen2.5-1.5B-Instruct，目标奖励采用 Skywork-Reward-V2-Llama-3.2-3B。奖励端冻结表示，只训练线性头；策略端限制在最后一层的低秩适配参数中。这样的设计控制了可训练空间，使方法之间的差异更容易解释。

实现中的一个难点是 Fisher 相关计算。局部参数空间为 7,168 维，直接构造并求逆一个稠密矩阵既昂贵，也容易放大数值误差。我使用共轭梯度方法计算逆矩阵与向量的乘积，并加入阻尼。试跑时同时检查求解残差、参数移动和更新后的 KL，避免将数值不稳定误认为策略大幅改善。

有限重复偏好标注还带来另一个问题：经验胜率取对数几率后，会产生非线性偏差，极端胜率也无法直接使用。实验在有限标注组中采用相应的奖励差估计构造，并与使用精确奖励差的一组分开比较。它检验的是噪声信号下方法是否仍有作用，不是真人偏好实验。

正式实验固定阻尼系数为 10，并采用五折交叉拟合。报告中需要区分固定配置和实验发现：阻尼是本轮共同使用的数值设置，不能被写成经过全面搜索后的最优参数。第三周的实现工作主要是让理论对象、训练输入和策略更新对应起来，为第四周在相同规则下比较各条流程做好准备。

冻结实验与主要结果

第四周完成正式三种子实验与结果汇总。本实验从 MultiPref 提取 4,608 条提示，其中 3,072 条用于训练、512 条用于验证、512 条用于正式测试，另保留 512 条。每个提示生成 6 个候选回答，形成 15 个无序回答对。偏好信号由合成奖励机制产生；正式评价不复用奖励训练时的回答。

实验分别使用精确奖励差信号和有限重复偏好标注信号，在每组内比较 MLE、MSE 和 ProRM；再加入直接目标奖励与未更新参考策略，共八条流程。策略更新均使用相同的局部空间与系数。每个种子、每条策略都在 512 个测试提示上重新生成 6 个回答，合计 $3 \times 8 \times 512 \times 6 = 73,728$ 条。

方法	偏好 NLL 越低越好	策略效用 J 越高越好
O-MLE	0.68345 ± 0.00109	0.01599 ± 0.00960
O-Pro	0.73285 ± 0.00318	0.02068 ± 0.01837
H-MLE	0.68905 ± 0.00217	0.01768 ± 0.00817
H-Pro	0.75072 ± 0.00586	0.02000 ± 0.01729

表 8 三个随机种子的均值与样本标准差

表中的 J 是目标奖励减去 0.2 倍 KL 成本后的策略效用，均值和样本标准差均按三个种子计算。O 表示精确信号组，H 表示有限标注组。ProRM 在两组中的 J 均值最高；但这只是三种子描述性结果，不能据此声称显著优于所有基线。

更有研究意义的是，O-Pro 的奖励拟合指标并非组内最佳，却取得较高的下游效用均值。这说明在当前设置中，奖励拟合排序与策略评价排序可以分离。H-Pro 与 O-Pro 均值相差约 0.00068，明显小于各自的种子间波动，现有结果也不足以证明两种信号统计等价。

我在整理结果时分别检查了训练端与策略端。偏好 NLL 回答奖励模型能否解释比较标签；J 回答用该奖励更新后，新生成回答的收益是否值得其 KL 成本。73,728 条回答给出了完整的生成评价记录，但它们共享提示、策略和随机种子，不能当作 73,728 次独立实验。本轮结论应停留在机制层面：优化奖励拟合指标和优化下游策略，确实可能选择不同的方法。

暑研答辩与阶段完成

完成实验汇总后，我把选题动机、理论对象、机制实验和主要结果整理为最终汇报。答辩题目为 **Prospective Reward Modeling**，重点说明为何按下游策略遗憾训练奖励模型，以及该想法如何在受限的大模型更新中实现。下图为本次暑研最终答辩现场。




图 5 2026 年 8 月港科大 IEDA 暑研最终答辩现场

准备最终汇报时，我需要把公式与结果之间的关系讲清楚。奖励模型的训练目标、局部策略更新和重新生成回答的评价是三个不同环节；如果只展示拟合表，听众无法判断研究是否真正走到了策略层面。因此，汇报保留了完整的实验比较，并同时呈现均值与波动。

本次暑研阶段的预定工作已经完成：基础学习和文献汇报形成了问题，手写推导给出了目标，HPC4 实验完成了训练、更新、生成和评价，最终报告与答辩对结果作了说明。研究仍可继续扩展到真人偏好、更大模型或多轮更新，但这些属于后续工作，不改变这一暑研阶段已经完成的事实。

我的主要收获是学会为直觉寻找恰当的验证方式。理论上可以说明某种误差为何重要，实验上还要确认这种差异能否传递到新生成的回答；与此同时，合成目标奖励只定义了本次实验的评价标准，不能代替人的真实需求。保持这两层区别，是我在整理结果时反复检查的地方。

实践体会与后续工作

这次实践改变了我阅读指标的顺序。面对今井达也的高失分结果，我先检查三振、挥空、控球与侧别，再判断哪些调整值得尝试；面对奖励模型的拟合结果，我先追问它是否真的改善了后续策略。两项工作都使我更重视指标所服务的任务，减少了对某个漂亮数字的依赖。

我也更加清楚地认识到分析者的责任。公开数据能够提示球队应先检查什么，却无法替代医疗、动作和教练判断；三个种子的机制实验能够支持继续研究，却不足以证明方法适用于所有大模型对齐场景。把这些限制与结论一起说明，可以让建议保留实际用途，也给后续验证留下明确方向。

在具体工作方法上，我会继续保留三个习惯：计算前写清分析单位与分母；出现结果后检查替代解释；提交前核对数据、图表与文字是否一致。对于 MLB 项目，下一步是用新增比赛检验过程指标与负荷安排，并结合可获得的球路、位置和健康信息修正建议。对于 ProRM，下一步是在保持评价规则清楚的前提下，增加重复实验并逐步扩大研究范围。

最终成果包括可复核的 MLB 数据与代码、今井达也调整建议，以及完整的港科暑研报告与答辩材料。我希望这份报告呈现的不仅是工作量，也包括判断如何随着证据改变。今后独立承担分析任务时，我仍会沿用这种从问题到数据、再到行动与验证的工作方式。

主要参考资料

[1] MLB StatsAPI, 今井达也 2026 赛季比赛日志; Baseball Savant, Statcast 逐球数据与 Pitch Arsenal。数据冻结至 2026 年 8 月 12 日，原始快照与来源网址见项目仓库 `data/raw/source_manifest.csv`。

[2] NPB 官方球员统计; NPB Basement 高级投球与球种资料。NPB 重点比较年份为 2025 年，跨联盟标签与价值指标分别解释。

[3] Rafailov 等, Direct Preference Optimization: Your Language Model is Secretly a Reward Model, NeurIPS, 2023。原文: arxiv.org/abs/2305.18290。

[4] Elmachtoub 与 Grigas, Smart “Predict, then Optimize”, Management Science, 2022, 68(1): 9–26。DOI: 10.1287/mnsc.2020.3922。

[5] Nika 等, Reward Model Learning vs. Direct Policy Optimization: A Comparative Analysis of Learning from Human Preferences, ICML, 2024, PMLR 235: 38145–38186。原文: proceedings.mlr.press/v235/nika24a.html。

[6] 本人暑研材料: 2026 年 7 月 14 日阶段汇报、手写推导、最终答辩 Pre.pdf 及阶段实验报告 report111.pdf。模型与数据配置按阶段实验报告记录。

项目与公开来源入口: <https://github.com/youth-flow/MLB-Analytics>。本文 MLB 数字均采用 8 月 12 日冻结窗口，不将其表述为 9 月实时表现。