

底稿 02 数据来源与指标口径

今井达也 MLB 调整决策 | 数据截止 2026 年 8 月 12 日

MLBAM ID 837227 | 8 类来源、17 份原始快照 | 最终版本 9c8033d

一、版本与分析单位

本次分析覆盖 2026 年 3 月 29 日至 8 月 12 日。比赛日志负责场次、角色、局数和官方结果；打席用于 K%、BB% 及角色比较；逐球用于球种、球数、挥棒、打者侧别和轮次。三层数据各有分母，不能混用。

比赛日志中的 64.2 局采用棒球记分法，表示 64 局加 2 个出局数，即 64 又 2/3 局；计算 ERA 时先统一换算为 194 个出局数，不能把 64.2 当作十进制局数。

原始网页、JSON 和 CSV 共 17 份，保存在 data/raw，下载时间、字节数和 SHA-256 列在 data/raw/source_manifest.csv。处理表写入 data/processed，不会覆盖原始快照。默认运行使用冻结文件；只有明确执行 python scripts/run_pipeline.py --refresh-data 时才联网建立新窗口。

二、八类来源及职责

编号	来源	用途	本地文件	限制
S1	MLB StatsAPI	17 场、角色、局数、K、BB、ERA 核对	mlb_statsapi_game_log_2026.js on; mlb_game_log_2026.csv	不含完整逐球位置
S2	Baseball Savant Statcast Search	球种、球数、zone、挥棒、侧别、轮次、逐球价值	statcast_imai_2026.csv	1 条自动坏球无球种标签
S3	Savant Expected Statistics	ERA、xERA 和赛季级指标	savant_expected_stats_pitchers_2026.csv	赛季汇总，不替代逐球
S4	Savant Pitch Arsenal	球种使用、Whiff、wOBA/xwOBA、官方 RV	savant_pitch_arsenal_stats_2026.csv	低频球种波动大
S5	NPB 官方球员页	2018—2025 传统投球统计	npb_imai_player_page.html; npb_imai_pitching_2018_2025.csv	粒度较低
S6	NPB Basement（第三方）	2023—2025 高级指标、球种、球速和 xPV	npb_basement_*.js; npb_basement_imai_*.csv	非官方；价值模型与 MLB 不同
S7	MLB.com, 2026-05-31	适应与健康背景	mlb_imai_adjustment_article_2026-05-31.html	只作语境
S8	MLB.com, 2026-07-31	转入牛棚的时间背景	mlb_imai_bullpen_article_2026-07-31.html	只作语境

三、清洗与对账

Statcast 原始文件有 1,241 行。其中一条自动坏球事件没有球种标签，原始记录保留，球种主分析使用其余 1,240 行。三振、保送、比赛数和角色以 StatsAPI 核对。qa/data_reconciliation.csv 给出四项差值：

校验项	处理结果	官方参考	差值
带球种标签投球	1,240	1,240	0
三振	80	80	0
保送	42	42	0
比赛	17	17	0

差值为 0 说明主样本与官方结果闭合，不能代替对结论的判断。异常行没有被强行补球种，也没有影响 K、BB 或场次计算。

四、指标字典

指标	分子与分母	原始字段/来源	主要输出	解释限制
K%	80 K / 288 BF	StatsAPI	analysis_summary.json	跨联盟环境不同
BB%	42 BB / 288 BF	StatsAPI	analysis_summary.json	同上
K-BB%	K%-BB%	上述两项	analysis_summary.json	仍受对手质量影响
Zone%	zone 为 1—9 的 541 球 / 1,240 个带球种标签投球	Statcast zone	汇总及 type/hand/count/role/TTO 表	不等于位置质量
首球好球率	149 / 288；排除五类坏球结果	pitch_number、description	汇总及 role 表	只看第一球，不等于首球进区率
Whiff%	175 次挥空 / 542 次挥棒	description	汇总及 type/hand/role 表	必须报告挥棒分母
Chase%	190 次区外挥棒 / 699 个区外球	zone、description	汇总及 hand/role 表	受位置和球种混合影响
Usage%	某球种球数 / 1,240	pitch_type	mlb_pitch_type_summary.csv	低频球种不稳定
官方 RV	Savant Pitch Arsenal 公布值	run_value	mlb_pitch_type_summary.csv	只在 MLB 官方口径内解释
重算 RV/100	$\Sigma \text{delta_pitcher_run_exp} / \text{球数} \times 100$	Statcast 逐球	type/hand/count/TTO 表	正值对投手有利；不可与 NPB xPV 直减
Wilson 95%区间	二项比例区间	Zone、首球、Whiff、Chase	mlb_process_metrics_by_role.csv	小样本区间较宽

首球好球包括 called strike、swinging strike、foul 和 in play 等结果；排除 ball、blocked ball、hit by pitch、automatic ball 与 pitchout。分组规则另行固定：先按 StatsAPI 逐场记录判断角色，当场 gamesStarted==1 记为先发，其余出场记为牛棚；打者侧别使用 Statcast stand；球数使用 balls 和 strikes；面对打线轮次先筛选先发场次，再直接按 n_thruorder_pitcher 分组。轮次和角色比较都是描述性结果。

五、输出文件索引

- 总览：data/processed/analysis_summary.json、mlb_game_log_2026.csv。
- 球种与分层：mlb_pitch_type_summary.csv、mlb_pitch_metrics_by_batter_hand.csv、mlb_pitch_metrics_by_count.csv。
- 角色与轮次：mlb_process_metrics_by_role.csv、mlb_times_through_order.csv。
- 跨联盟：npb_2025_vs_mlb_2026_outcomes.csv、npb_2025_vs_mlb_2026_pitch_mix.csv 及四份 npb_*处理表。
- 对账：qa/data_reconciliation.csv；完整来源 URL：docs/research/source_register.md。

任何新窗口都必须先更新来源清单和截止日，再重跑处理与报告。不能只替换 Word 中的赛季数字。