

底稿 04 复现与交付核查说明

冻结数据、自动校验、逐页检查与过程记录

项目：MLB-Analytics | 数据截止：2026 年 8 月 12 日 | 最终版本：9c8033d

一、离线复现

项目默认读取 data/raw 中的 17 份冻结快照，不主动访问网络。环境为 Python 3.12；主要依赖固定在 requirements.txt，包括 numpy 2.3.5、pandas 3.0.1、python-docx 1.2.0、lxml 6.1.1 和 pypdf 6.10.0。

进入 MLB-Analytics 目录后运行：

```
python scripts/run_pipeline.py
```

该命令依次完成分析、报告生成和自动校验。单元测试另行运行：

```
python -m unittest discover -s tests -v
```

只有需要建立新的赛季窗口时才运行 python scripts/run_pipeline.py --refresh-data。联网刷新会改变下载时间和网页内容，因此必须同时更新截止日、来源清单、处理表和报告，不能继续引用旧窗口。

二、自动校验状态

截至最终 commit 9c8033d，本地 main 与 origin/main 一致；GitHub Actions run 31870800186 成功。qa/integrity_report.json 记录默认离线自动结果，严格视觉结果写入 qa/local_visual_report.json；两类结果的职责分开。核查摘要如下：

检查项	对象	状态
来源哈希	17 份原始快照与 manifest 逐字节比较	通过
数据对账	1,240 球、80K、42BB、17 场	四项差值 0
核心结果	冻结数字断言	通过
公开 Word 结构	A4、标题、字体、朴素样式和嵌图；正式稿首段加粗	通过
公开文件隐私	24 份文件扫描姓名、学号等信息	未发现
产物清单	45 项、顺序确定、无缓存路径泄漏	通过
单元测试	离线流程、完整性和报告结构	12 项通过
远程 CI	Windows 下离线重建与 byte-stable 检查	通过

仓库提交 9c8033d 中的两份公开 Word 曾使用 LibreOffice 26.2.5.2 渲染为 150 dpi 逐页图：两页决策稿 2 页，仓库版完整分析底稿 10 页。逐页检查未发现截断、重叠、乱码和异常分页；曾出现的来源孤页已消除。qa/visual_review_receipt.json 记录页数、文件哈希、审阅时间和检查项；运行 python scripts/verify_project.py --require-visual 后，render_verification=passed、

manual_visual_qa=reviewed、submission_ready=true。本次提交材料另按学校与单位用途排版，页数以同目录清单为准。

三、推断限制

- Zone%按 Statcast zone 字段 1—9 计算，不代表具体位置质量。
- 先发与牛棚不是随机实验；23 个牛棚打席不能给出角色因果。
- MLB 变速球只有 29 球，62.5% Whiff 来自 5/8 次挥棒，不能外推长期效果。
- NPB 与 MLB 环境和价值模型不同，NPB xPV/100 不与 MLB Run Value/100 直接相减。
- 面对打线轮次先筛选先发，再直接使用 n_thruorder_pitcher，只作描述。
- 医疗、握法和动作信息不在公开数据中；统计阈值不能替代球队评估。

四、过程留痕与工具边界

为保证过程可追溯，本项目记录了资料抓取、代码编写、计算、初稿分析和 Word 排版中的工具使用。工具输出不作为事实来源；数值证据均回到冻结快照、处理表或正式网页，观察性分组没有改写成因果，未取得的球队内部信息也没有补写。研究问题、指标口径、异常处理和最终判断由提交者逐项复核。

最初任务及后续提示记录在 docs/research/ai_prompt_log.md，判断变化记录在 docs/research/hypothesis_log.md 与 docs/research/analysis_cycle_results.md。资料获取、数据冻结、初步诊断、球种修正、角色反证和成稿检查都能回到相应记录。本说明只交代复现和核查；分析判断为什么改变集中写在底稿 03，不在此重复。

五、最终 Word 检查

检查项	通过标准	本轮状态
两页决策稿	A4 不超过 2 页；9pt 微软雅黑；首段论点加粗	2 页，通过
五份 MLB 文档	无截断、重叠、空白页和孤立标题	2、7、3、2、2 页，均通过
事实与边界	核心数字可回到 CSV；小样本和观察性措辞准确	通过
身份与版本	姓名、学号、截止日、仓库 commit 一致	通过；仓库版本 9c8033d
文件完整性	文件可打开；记录页数、SHA-256 和修改时间	通过；校验值见同目录清单

五份本次 MLB 材料已用 Microsoft Word 直接打开并逐页检查；仓库两页决策稿和仓库版完整分析底稿的严格门禁也已通过。