

浙江大学管理学院

本科生短学期分散实习报告

MLB 投手数据分析实践与港科大 IEDA 暑研总结

学生姓名	杨炎新
学号	3230102355
实习单位	上海思搏动态智能科技有限公司
校内指导教师	陈发动
实习时间	2026.07.09—2026.09.13（计划周期；本报告整理截至2026.08.15）

摘要

本次短学期实践以公开体育数据分析为主体。我选择课程题目“今井达也在 MLB 应如何调整和发展”，将其进一步收敛为一个可以执行的决策问题：今井目前的困难主要来自球威、控球、球种结构还是先发负荷，球队应依据哪些可观测条件让他重返先发轮值。研究使用 MLB StatsAPI、Baseball Savant、NPB 官方和 NPB Basement 资料，冻结至 2026 年 8 月 12 日，共覆盖 17 场比赛、288 个打席和 1,240 个带球种标签的投球。分析从结果指标、过程指标、球种、打者侧别和角色五个层次展开。

结果显示，今井的三振与挥空能力并未整体消失，K% 仍为 27.8%，四缝线均速也与 NPB 2025 接近；更明显的变化是 BB% 由 7.0% 升至 14.6%，Zone% 和首球好球率偏低。球种方面，滑球仍有正向价值，但 2025 年在 NPB 稳定使用的变速球到 MLB 后使用率从 12.7% 降至 2.3%，与四缝线的速度差也缩小。四缝线风险主要集中在左打者。两次牛棚登板的过程指标方向积极，但只有 23 个打席，不能据此判断永久后援优于先发。基于这些证据，我提出多局牛棚校准：先至少积累 60 个打席，此后启用滚动最近 60 打席过程门槛，再通过 45、60、75 球负荷阶梯逐步回到先发，并明确健康异常和控球反复时的退阶条件。

报告还总结了我同期在香港科技大学工业工程与决策分析系完成的 Prospective Reward Modeling 暑研。该项目把 Smart Predict-then-Optimize 的思想引入大模型对齐，以奖励模型诱导策略的下游效用而非单纯偏好拟合误差作为评价重点。暑研第一阶段完成 RLHF 与 DPO 学习、局部 regret 理论推导、HPC4 上的 Synthetic-oracle 机制实验、三随机种子 73,728 条 fresh rollout 汇总及最终答辩。两项实践共同训练了我界定问题、治理数据、检验反例、执行实验和克制表达结论的能力。

关键词： MLB；Statcast；控球；球种结构；决策门槛；RLHF；DPO；Prospective Reward Modeling；policy regret

一、实践概况与任务选择

1.1 实践内容

本次分散实习由上海思搏动态智能科技有限公司作为接收单位。我的主体任务是完成一项能够独立复核的数据分析作业，并把分析过程整理为正式文稿、计算底

稿和可复现项目。同期，我在香港科技大学 IEDA 系跟随 Sinian 教授完成了一个多月的大模型对齐暑研。两项任务都涉及数据与模型，但受众和目标不同：MLB 项目面向现实角色决策，要求把公开数据转成清楚、可操作的建议；港科项目面向研究问题，要求从理论推导走到受控实验。

我一开始低估了“问题定义”的工作量。棒球题目看似只需搜集数据并作比较，但“今井表现为什么不好”和“球队下一步怎么安排”并不是同一个问题。前者容易停在解释过去，后者必须给出动作、观察指标和改变判断的条件。同样，在 reward modeling 中，偏好预测准确并不等于策略更新有效。两条工作线最终都把注意力放到了下游结果上。

为复盘方法，我把两项工作按内容先后分成四个阶段：选题与理论学习、数据治理与公式推导、分层分析与 HPC4 试跑、决策交付与暑研答辩。这里的“阶段”描述任务顺序，不表示 MLB 工作平均分散在四个自然周；MLB 课程项目在 8 月集中整理并形成仓库，港科暑研则按实际学习、推导、实验和答辩进度记录。数据来源和假设在后续分析中仍会回查，MLB 窗口在成稿时更新到 8 月 12 日；港科实验遇到实现问题时，也需要返回局部理论核对矩阵和评价对象。

阶段	MLB 数据分析	港科暑研	主要产出
阶段一	收敛决策问题，登记公开来源	学习 RLHF、DPO 并完成组会汇报	研究问题、假设、文献汇报
阶段二	冻结数据，统一指标并对账	推导 reward utility 与 local regret	数据字典、手写推导
阶段三	控球、球种、侧别和角色分析	HPC4 数据物化与端到端试跑	分层结果、初步实验
阶段四	形成管理规则、底稿和复现项目	完成三种子实验并答辩	决策文稿、报告与实验结果

1.2 我承担的工作

按课程要求，我对资料获取、代码计算、写作修订和排版过程分别留痕。我先明确研究问题、数据截止日、交付对象和验收标准，再由生成式工具协助执行资料抓取、代码计算、图表生成、反证搜索和初稿迭代。工具输出不直接作为事实来源；核心数字回到原始快照、处理表或官方页面核验，指标口径、异常处理和结论边界也在每轮修改后重新检查。分步提示、阶段总结和判断变化与代码、数据一并保留，便于如实查看人机协作过程，而不只是阅读最后结论。

港科暑研中，我负责阅读 alignment 相关工作、准备阶段汇报、进行 Prospective Reward Modeling 理论推导，并在 HPC4 上完成实验实现、结果整理和答辩。导师在研究方向、理论表达和实验设计上提供指导。我将两类经历放在同一份实践报告中，是因为它们共同反映了我从开放问题到可验证结论的学习过程；涉及实习单位审阅的汇总和底稿则只保留 MLB 项目。

二、MLB 数据分析项目

2.1 从高 ERA 解释转向重返先发决策

今井达也 2026 年进入 MLB 后，冻结窗口内 ERA 为 5.29，xERA 为 4.89。最直接的写法是将这些数字与 NPB 时期成绩并列，再归因于联盟强度、适应或伤病。但这种解释过于宽泛，也很难落到行动。我把问题拆成五个可以被数据推翻的判断：核心球威是否保留；保送和早期球数控制是否是主要损失来源；四缝线与滑球的高占比是否隐藏侧别风险；牛棚改善能否代表长期角色；低频第三球种是否在 NPB 时期已经成熟。

在查看分组结果前，我为每个判断写下证伪条件。例如，如果 K%和 Whiff%都明显下降，“球威保留”就不成立；如果牛棚样本很少且比例区间与先发重叠，就不能写成角色改变带来因果提升；如果第三轮面对打线的球速和价值没有同步恶化，则“先发困难主要来自第三轮疲劳”缺少支持。这些约束让我在看到结果后仍能保留相反证据。

研究单位分为比赛、打席和逐球三层。比赛日志用来确定 17 场、15 次先发、2 次牛棚和 64 又 2/3 局（官方记分为 64.2 局）；288 个打席用于 K%、BB%及角色比较；1,240 个有球种标签的投球用于球种、位置、挥棒、侧别和球数。分层之后，ERA 只是背景，真正与训练和角色安排相关的是可重复观察的过程指标。

2.2 数据来源与冻结方式

MLB 数据主要来自四类官方或公开页面。StatsAPI 给出比赛日志、角色、局数、三振和保送；Baseball Savant Statcast Search 提供逐球球种、坐标、球数、挥棒和结果；Expected Statistics 用于核对 xERA 等赛季指标；Pitch Arsenal 提供各球种使用率、Whiff、wOBA/xwOBA 和官方 Run Value[1—2]。MLB.com 的两篇报道只确认适应、伤情与转入牛棚的时间背景，不替代数值分析[13—14]。

NPB 官方球员页用于核对 2018—2025 年的传统统计，第三方网站 NPB Basement 补充 2023—2025 年的高级投球、plate discipline 和球种数据。跨联盟数据的作用是识别结构变化，比如某个球种是否长期使用、迁移后是否几乎消失，而不是把 NPB xPV/100 和 MLB Run Value/100 当成完全可比的价值尺度[3—4]。

来源	分析用途	本地留存	使用边界
MLB StatsAPI	比赛、角色、局数、K 和 BB	JSON 与比赛表	不提供完整逐球位置
Baseball Savant	逐球、xERA、球种价值	CSV 与页面快照	自动事件和小样本需核对
NPB 官方	职业传统统计	页面快照与处理表	粒度低于 Statcast
NPB Basement	高级指标与球种历史	HTML、脚本和处理表	价值模型不可跨联盟直减
MLB.com	伤情和角色背景	HTML 快照	只作语境，不作数值证据

我为 17 份原始文件记录 URL、下载时间、文件大小和 SHA-256，原始快照只读保存在 data/raw，处理表写入 data/processed。默认复现从冻结快照开始，不重新请求动态网页。若赛季窗口更新，必须生成新的截止日和来源清单；若只是检查计算，则保持原始文件不变。

清洗中发现一条自动坏球事件没有球种标签。原始 Statcast 共 1,241 行，球种分析使用其余 1,240 行，但比赛、三振和保送仍由 StatsAPI 核对。最终逐球数、三振数、保送数和比赛数四项差值均为 0。这个异常很小，却提醒我不能为了让表格整齐而无记录地删行，也不能用猜测补上缺失球种。

2.2.1 从动态网页到冻结证据

公开体育数据并不是一张下载后就永远不变的表。Savant 的赛季页会随新比赛继续更新，StatsAPI 返回的比赛日志也可能在记录修正后发生变化。如果只在 Word 中写“截至 8 月 12 日”，却不保存当时的原始响应，之后再运行同一个 URL 就可能得到另一批数据。因此，抓取阶段先固定球员 MLBAM 编号 837227 和日期窗口，再将 HTTP 响应以原始字节写入 data/raw，同时记录请求地址、本地文件名、下载时间、文件大小和 SHA-256。处理脚本不直接依赖远程页面，而是读取这些冻结文件。

不同来源的留存方式也不一样。StatsAPI 的 JSON 结构化程度高，可以直接保留；Statcast Search 返回的 CSV 需要另存字段和行序；Savant 的 Expected Statistics 和

Pitch Arsenal 分别提供赛季级与球种级对照；NPB 官方页与 NPB Basement 则包含 HTML 和前端脚本，处理时要先确认页面展示值对应的赛季、球种和单位。第三方 NPB 数据不因为粒度更细就被写成官方真值，底稿中始终标明其性质和不能跨联盟直减的限制。

冻结之后还要检查“获取成功”是否等于“内容正确”。项目对每份原始文件执行存在性、字节数、哈希和基本字段检查，再用官方比赛日志对照处理后的比赛数、三振和保送。对于无球种的自动坏球，处理策略是保留原始行、在球种表中排除、在异常记录中解释影响范围。这样既不会伪造球种，也不会让不同表格的分母在无说明的情况下发生变化。

为了区分“重现冻结结论”和“刷新最新数据”，管线默认离线运行，只有显式传入 `--refresh-data` 时才重新请求网络。前者应该得到与已提交报告一致的处理表和图表；后者实质上建立了一个新研究窗口，需要重新登记截止日、原始哈希和后续结论。这一区分使仓库不仅能运行，还能说明每次运行回答的究竟是哪一个数据版本。

2.3 指标口径

结果指标包括 ERA、xERA、K%、BB%和 K-BB%。K%和 BB%的分母都是打席，K-BB%反映制造出局与免费上垒之间的净差。过程指标包括 Zone%、首球好球率、Whiff%和 Chase%。Zone%以带球种标签的投球为分母，首球好球率以每个打席第一球为单位，Whiff%只在挥棒集合中计算，Chase%只在好球区外投球中计算。

球种层面记录使用率、平均球速、Whiff、wOBA/xwOBA 和投手视角 Run Value。正 Run Value 表示对投手有利，RV/100 用于在同一联盟和同一口径下比较球种分组。角色由 StatsAPI 的 gamesStarted 标记确定；面对打线轮次先筛选先发场次，再直接使用 Statcast 的 n_thruorder_pitcher，只作描述。对于牛棚 23 个打席和变速球 29 球等低频组，我保留样本量与 Wilson 区间，不把方向变化写成稳定能力。

指标	分母	回答的问题	主要限制
K%、BB%、K-BB%	打席	能否结束打席、是否免费上垒	受联盟环境影响
Zone%、首球好球率	投球、打席首球	能否建立有利球数	未完全表达进区位置
Whiff%、Chase%	挥棒、区外投球	球威和诱导能力	受球种与情境混合影响

指标	分母	回答的问题	主要限制
Usage%、RV/100	带标签投球	球种结构与结果方向	小样本和模型口径

2.3.1 指标如何落到计算与对账

计算没有从同一张逐球表中硬算所有指标，而是按照比赛、打席和投球三个层次分别确定分母。比赛日志中的“64.2 局”是棒球记分法，表示 64 局又 2 个出局数，不能当作十进制 64.2。处理时先换算为 $64 \times 3 + 2 = 194$ 个出局数，再用 $38 \times 27 \div 194$ 得到 ERA 5.29。三振率和保送率以 288 个打席为分母，分别为 $80 \div 288 = 27.78\%$ 和 $42 \div 288 = 14.58\%$ ，K-BB%则为 $(80 - 42) \div 288 = 13.19\%$ 。代码专门保留“局数转出局数”的函数，并用 5.1 局等于 16 个出局数、64.2 局等于 194 个出局数的测试防止记分口径被误读。比赛数、局数、K 和 BB 均以 StatsAPI 日志为基准，没有依赖逐球事件自行拼接。

逐球指标使用 1,240 个有球种标签的 Statcast 投球。Zone%直接按 Savant 的 zone 字段判断，1 至 9 区记为区内，本样本为 $541 \div 1,240 = 43.63\%$ 。首球好球率先筛选每个打席的第一球，再把 ball、blocked ball、hit by pitch、automatic ball 和 pitchout 以外的结果记为好球，得到 $149 \div 288 = 51.74\%$ 。Whiff%的分母不是全部投球，而是 542 次挥棒；按项目逐球定义，挥空包括 swinging strike、blocked swinging strike、foul tip 和 missed bunt，共 175 次，因此 $\text{Whiff}\% = 175 \div 542 = 32.29\%$ 。Chase%的分母是 699 个区外投球，其中 190 次发生挥棒，结果为 27.18%。把分子和分母一起保留，可以判断比例变化究竟来自能力变化还是样本构成。

先发与牛棚样本差距较大，所以报告没有只比较两个点估计，而是使用 $z=1.96$ 的 Wilson 区间：

$$CI = [\hat{p} + z^2/(2n) \pm z\sqrt{(\hat{p}(1-\hat{p})/n + z^2/(4n^2))}] / [1 + z^2/n]$$

先发 Zone%为 43.4%，95%区间为 40.6%—46.3%；牛棚 Zone%为 46.1%，区间为 36.1%—56.4%。牛棚首球好球率虽然达到 73.9%，区间仍为 53.5%—87.5%。因此牛棚结果只写成“方向积极”，没有把两个比例的差异直接解释为角色改变产生了稳定效果。

球种价值使用投手视角的 delta_pitcher_run_exp，按“该组投手 Run Value 之和 $\div$ 投球数 $\times 100$ ”重算 RV/100。例如，滑球 562 球的累计值为 3.625，重算 RV/100 为

+0.645，与 Pitch Arsenal 显示的+0.6 只存在四舍五入差异；四缝线 540 球的累计值为 -0.601，重算值为-0.111，对应官方-0.1。最后，1,240 个带标签投球与 Pitch Arsenal 球数、逐球终结事件中的 80 次三振和 42 次保送与 StatsAPI、17 个唯一比赛编号与比赛日志逐项对账，四项差值均为 0。NPB 数据分别由官方球员页和第三方网站 NPB Basement 核对，只比较球种结构和联盟内价值方向。

2.3.2 从字段到分子分母的复核

指标名称相同，计算规则也可能不同。例如“首球好球”不能简单写成 description 包含 strike，因为界外球、击球进场、触身球和自动判罚需要按比赛规则分别处理。项目先用 pitch_number==1 选出每个打席的第一球，再将 ball、blocked ball、hit by pitch、automatic ball 和 pitchout 等坏球结果排除，其余记为好球结果。这一方法不会把所有首球都归结到 zone 坐标，也能处理挥棒或击球发生在好球区外的情况。最终 149 个好球结果与 288 个打席首球一一对应，避免了同一打席被重复计数。

Whiff 的计算则先定义挥棒集合，再在其中定义挥空子集。挥棒包括 swinging strike、foul、foul tip、hit into play、foul bunt 和 missed bunt 等结果；挥空包括 swinging strike、blocked swinging strike、foul tip 和 missed bunt。如果直接用全部 1,240 球作分母，得到的只是“每球挥空比例”，会将看球和挥棒决策与球种在挥棒后的欺骗能力混在一起。保留 542 次挥棒和 175 次挥空这两个计数，使 32.3%不再是一个无法检查的小数。变速球的 62.5%更需要同时写成 5/8，否则读者容易误以为 29 球都进入了分母。

Chase 与 Zone 的关系也需要先固定。Zone%使用 Statcast 已给出的 zone 标签，1 至 9 为区内，其余带标签球为区外；并没有用 plate_x 和 plate_z 自行重画一个与官方可能不同的好球区。Chase 的分母是 699 个区外球，分子是其中 190 次发生挥棒的记录。这个指标可以说明区外球是否获得挥棒，但不说明区外球距离边界多远，也不能分离球种和球数情境。因此，训练建议中将它与 Zone、首球和球种分组一起读，没有单独设置 Chase 升级门槛。

角色与面对打线轮次的复核关注是映射而非公式。每场比赛先通过 StatsAPI 的 gamesStarted 判定今井是否先发，再用 game_pk 将角色标记回填到逐球数据。TTO 只保留先发场次，并直接按 n_thruorder_pitcher 分组，没有根据 at_bat_number 自己推算第几轮。通过先检查每个角色组的唯一比赛数、打席数和投球数，可以及时发现某场角色映射缺失、或牛棚球被误纳入 TTO 的问题。

Wilson 区间的使用也只是为了展示不确定性，不等于已经完成了先发与牛棚的因果检验。两组区间宽度不同，首先反映的是样本量差异；即使点估计相差很大，牛棚样本仍可以兼容很宽的真实范围。报告因此将区间作为约束表述的工具：它可以防止把 73.9%当成精确稳定能力，但不能仅凭“区间是否重叠”决定球员长期角色。

2.4 发现一：三振能力保留，控球成为首要问题

截至 8 月 12 日，今井 MLB K%为 27.8%，与 NPB 2025 的 27.8%相同；逐球 Whiff%为 32.3%，高于 Savant 同页 25.0%的 MLB 平均。四缝线均速 94.86 mph，也几乎等于 NPB 2025 的 94.87 mph。K%、挥空和球速共同说明，至少不能把表现不佳概括为“球威整体消失”。

保送和早期球数控制却明显恶化。BB%从 NPB 2025 的 7.0%升到 14.6%，K-BB%由 20.7%降至 13.2%；Zone%只有 43.6%，首球好球率 51.7%，均低于 Savant 同页平均。Chase%为 27.2%，接近平均，说明打者并没有因为过度追逐坏球而替今井扩大好球区。更少的进区和首球好球会带来更深球数，也使仍然存在的挥空能力付出更高用球成本。

这组结果把训练优先级从“追求额外球速”改为“恢复可控的抢好球能力”。但我没有把 Zone%等同于命令质量。四缝线进区仍需考虑边界和高度，滑球要区分诱导挥棒的 chase 球与纯粹非竞争坏球。过程指标用于定位训练方向，不是让投手把所有球投到好球区中央。

诊断：三振能力保留，控球与球种结构发生退化

NPB 2025 与 MLB 2026 (截止 8 月 12 日)




图 1 今井达也 NPB 2025 与 MLB 2026 核心诊断（数据截至 2026 年 8 月 12 日）

2.5 发现二：需要恢复的是成熟变速球

MLB 中，今井滑球使用 45.3%，四缝线使用 43.5%，两者合计 88.9%。滑球 Whiff 为 40.6%，xwOBA 为.274，官方 Run Value 为+4，说明它的高使用率有实际基础。四缝线整体 Run Value 为-1，结果风险较大，却不能只看总值就全面减少，因为后续侧别分组显示它对右打仍有正向价值。

改变判断的关键是 NPB 历史。2025 年变速球使用率 12.7%、均速 84.7 mph、Whiff 41.6%，在 NPB 价值为正，显然不是偶尔试投的新球种。到 MLB 后只投 29 球，使用率降到 2.3%，均速升至 86.8 mph；四缝线仍约 94.9 mph，使两者速度差从约 10.1 mph 缩到 8.0 mph。29 球的 MLB Whiff 和结果不稳定，但使用率骤降和速度层收窄是可以确认的结构变化。

所以，我没有建议“开发任意第三球种”，而是建议先重建 2025 年已有证据的变速球。MLB 当前速度差已经约 8.0 mph，因此 8 mph 只能作为不再继续缩小的下限；可以尝试向 9—10 mph 恢复，同时由教练组检查落点、移动、释放和接触质量。比赛使用率逐步提高到 8%—12%，这一范围介于当前 2.3%和历史 12.7%之间，属于试验安排，不是能力真值。

2.6 发现三：四缝线风险集中在左打者

四缝线面对左打共 311 球，Whiff 为 15.4%，RV/100 为-1.27；面对右打 229 球，Whiff 为 27.0%，RV/100 为+1.47。滑球面对左右打的 RV/100 方向均为正。总表中的四缝线接近中性，其实掩盖了明显的侧别差异。

这一发现否定了“统一降低四缝线比例”的粗略方案。对右打，四缝线和滑球仍能构成主要框架；对左打，更需要修复四缝线位置，并加入变速球的速度与横向变化。变速球应先在左打方案中逐步增加，观察其早期轨迹、位置和接触质量是否稳定，再决定是否扩大到其他情境。

球数分组没有被写成固定暗号。例如，满球数四缝线的样本很少，不能据此规定“满球数只投四缝线”。实际训练目标应是让三种球在各自可执行区域内形成互补，而不是从小样本结果推导机械配球表。

2.7 发现四：牛棚是校准环境，不是永久答案

15 次先发的 Zone%、首球好球率和 Whiff% 分别为 43.4%、49.8% 和 31.6%；两次牛棚相应为 46.1%、73.9% 和 40.0%，Chase% 也从 26.4% 升到 37.5%。方向上看，缩短任务后今井更主动进入好球区，也保留了挥空。这是支持短期牛棚校准的现实信号。

问题在于牛棚只有 89 球、23 个打席，多项比例的 95% 区间很宽，并且角色改变与日期、伤病恢复、对手和比赛情境同时发生。四缝线均速从先发的 94.87 mph 略降到 94.72 mph，也不支持“短局数必然增加球速”。面对打线第三轮的 161 球没有明显球速下降，结果价值反而为正，至少说明不能预设今井每到第三轮就必然失效。

角色与侧别：牛棚改善是积极信号，但样本不足以证明永久转型

先发15场、1,151球；牛棚2场、89球




图2 角色与侧别分组：牛棚信号积极但样本有限，四缝线风险集中于左打

我最终把牛棚定位为训练与比赛之间的过渡环境，而不是长期身份标签。在更低的任务复杂度下，可以集中检查进区、首球选择和对左打变速球；是否回到传统先发，则交给扩大样本后的过程指标与健康状态决定。

2.8 重返先发的执行方案

建议从健康检查开始。右臂疲劳无复发后，保留 3—4 周的多局牛棚，每次 1—2 局，可尝试统一热身、休息和出手节奏。公开数据支持优先检查四缝线进区、滑球坏球质量，以及变速球速度差能否保持在约 8 mph 以上并向 9—10 mph 拉开；具体位置和动作目标需要球队内部数据。健康或动作异常时立即停止升级。

第二步是先至少积累 60 个打席，此后按滚动最近 60 个打席观察过程指标。升级要求 Zone% 不低于 46%，首球好球率不低于 60%，BB% 不高于 10%；变速球使用

率逐步达到 8%—12%，速度差、挥空和接触质量不能同时恶化。10%<BB%≤12%时维持当前负荷；BB%>12%或 Zone%、首球好球率持续未达时回到校准阶段。这些门槛综合了 MLB 平均、今井 NPB 历史和牛棚初始信号，作用是保持管理标准一致，并非声称 46%或 60%是统计估计出的真实分界。

通过过程门槛后，按 45、60、75 球增加负荷，每一级至少两次。除了总场结果，还要比较前后半段 Zone%、首球好球率、四缝线球速和变速球速度差。任一过程门槛未达时暂停升级；BB%>12%或 Zone%、首球好球率持续未达时回到校准阶段；仅当前负荷下出现后半段执行、球速或健康恶化时，退回上一负荷级。达到 60—75 球且持续稳定时，才进入传统先发；如果扩大样本后只在第三轮持续失效，可考虑一轮打线左右的短先发、跟随投手，或四至五局短先发。

阶段	主要安排	进入下一阶段的条件	未达标处理
校准	1—2 局多局牛棚，重建三球种	健康稳定，变速球逐步恢复	复查动作、握法和恢复情况
过程	先积累≥60 打席；此后滚动最近 60 打席	Zone≥46%，首球≥60%，BB≤10%	10%<BB≤12%时维持；BB>12%或 Zone、首球持续未达时回到校准阶段
负荷	45→60→75 球，每阶至少两次	后半段执行和球速稳定	任一门槛未达先暂停；控球持续未达回校准；仅负荷性退化时退一阶
角色	按扩大样本判断	60—75 球健康且稳定	一轮打线左右或四至五局短先发

2.8.1 门槛的来由与使用方式

这套方案中最容易被误读的部分是 46%、60%、10%和“先积累样本、再启用滚动 60 个打席”。它们不是用现有 23 个牛棚打席拟合出的最优切点，也不是球员能力的固定真值。它们的作用是将教练组的“看起来好一些”转成在每次登板后都能重复检查的管理规则。为避免给小数点制造假精确，我分别记录它们的比较对象、设置理由和改变条件。

管理项	当前值	参考信号	暂定标准的理由	何时调整
Zone%	43.6%	同页 MLB 平均约 48.7%；牛棚 46.1%	46%高于赛季当前值，又不要求立即达到联盟平均	样本扩大后与位置质量一并评估

管理项	当前值	参考信号	暂定标准的理由	何时调整
首球好球率	51.7%	同页 MLB 平均约 61.2%；牛棚 73.9%	60%用于要求更稳定地建立球数，不追逐两次牛棚的高点	若为达标而大量投入甘球，需下调或改用位置指标
BB%	14.6%	NPB 2025 为 7.0%	10%是从当前水平向历史水平回归的中间约束	必须和 Zone%、首球一起读，不以少数对手单独判断
变速球使用	2.3%	NPB 2025 为 12.7%	8%—12%是从当前到历史的渐进试验区	若位置、移动或接触质量恶化，暂停增加
观察窗口	23 个牛棚打席	当前区间过宽	先积累至少 60 个打席，此后滚动最近 60 个打席，可覆盖多次登板并降低单场对手影响	不是显著性所需的固定样本；根据健康和对手结构延长

这些条件必须成组使用。如果 BB%下降，但 Zone%和首球没有改善，可能只是当期对手挥棒更早；如果 Zone%上升，却伴随强接触大幅增加，也不能把“进区更多”视为进步。变速球同样不以使用率为唯一目标：速度差不再低于约 8 mph 只是底线，还要同时查看落点、移动、挥空和接触质量。门槛的价值在于迫使复盘使用同一组问题，而不是宣称它们永久正确。

2.8.2 一次登板后如何更新判断

实际执行时，每次登板的复盘可按固定顺序进行。第一步由医疗与体能人员确认当日疼痛、疲劳、恢复和动作状态；这一层不通过，后面任何数据都不能成为加量理由。第二步更新抢好球组：当场和滚动窗口的 Zone%、首球好球率、BB%及其分子分母。第三步检查球种结构：变速球是否在计划情境中使用，其速度差、位置、移动和接触质量是否同向。第四步才查看结果和负荷，比较前后半段的进区、球速和用球效率。

滚动窗口不会因为一场比赛结果好就归零，也不会因为一场失败就立刻重置结论。比如，一场零失分却出现多次满球数与深球数，在这套规则下仍然不会触发负荷升级；相反，某场因单支长打失分，但抢好球、球种执行和健康指标都稳定，也不应仅凭 ERA 否定整个校准过程。这种复盘方式把“结果好坏”和“过程是否正在变得可执行”分开，也使短期角色安排与长期先发决策之间有了可追踪的过渡。

2.8.3 什么新证据会改变方案

一份可更新的建议需要提前写清推翻条件。第一类是健康和动作证据。如果球队内部检查发现右臂疲劳未解决、释放点无法稳定，或为了降低变速球速度而出现可识别的动作变化，当前的 3—4 周校准计划就应让位于医疗恢复，不再用过程达标作为加量条件。公开数据无法直接判断这一层，因此医疗门禁必须放在决策树最前面。

第二类是控球与接触质量的组合证据。先积累至少 60 个打席，此后在滚动最近 60 个打席中，只有 Zone%、首球好球率和 BB%同时改善，且强接触和长打风险没有明显恶化，才支持进入负荷阶梯。如果进区率上升却是由更多中央甘球换来，就应重新定义四缝线的目标位置，而不是因为数字超过 46%就升级。反过来，若保送率在小样本中下降，但两项早期球数指标无改善，则更可能是对手或偶然性影响，校准不应宣布结束。

第三类是球种形态证据。现有公开分析只能确认变速球使用骤降、均速提高和与四缝线的速度差收窄，无法直接证明早期轨迹、握法或位移发生了什么变化。如果后续同口径运动学数据表明，速度差的改变并没有破坏与四缝线的分离，而且现有快变速球在位置和接触质量上更好，就不应为追求 9—10 mph 而强行降速。这也说明，速度差是待验证的技术线索，而不是单独的成功标准。

第四类是长负荷与角色证据。如果 45、60 和 75 球阶段的后半段持续出现进区下降、球速或球种形态衰减，并且在多次登板和不同对手上重复，才能将问题进一步定位为负荷或第三轮风险。那时一轮打线左右或四至五局的短先发、跟随投手才有更强根据。如果负荷增加后过程仍然稳定，则两次牛棚的好结果不应阻止他回到传统先发。通过提前写下这些反向条件，后续更新就有了具体对象，不会只因一场比赛的叙事改变方向。

2.9 局限与更新规则

公开数据无法替代球队内部的医疗、动作和运动学信息。2026 年右臂疲劳与角色变化混杂，先发和牛棚并非随机实验；NPB 与 MLB 的用球、球场、打者质量和追踪模型不同；MLB 变速球只有 29 球，牛棚只有 23 个打席；面对打线轮次直接使用 Statcast 字段，也只能作描述。所有分组结果都属于观察性证据。

这些限制直接决定更新方式。新增比赛后，应先按同一口径重算过程、球种、侧别和角色表，再检查决策树中哪一项条件改变。若追踪字段或好球区定义变化，需要重新审核清洗和指标；若健康约束变化，应从第一项重新评估。不能只把新 ERA 抄进旧报告，也不能因为一次高光就跳过过程观察。

2.10 一次跨平台复现失败及排查

项目在本机能够完整运行，但冻结管线推送到 GitHub 后，在 Windows runner 的旧式控制台编码环境中出现 UnicodeEncodeError。失败发生在结果已经算完、脚本准备向终端输出中文绝对路径和中文 JSON 时，因此最初看上去像是整个分析失败，实际生成的 CSV 和统计结果并没有损坏。

排查时把管线拆成数据读取、指标计算、文件写入和终端输出四步，再在较窄的控制台编码环境中分别重放。UTF-8 文件能够正常保存，报错只由终端无法编码中文字符引起。修复后，持久化报告和 JSON 继续使用 UTF-8 中文，控制台摘要改为 ASCII 安全输出：JSON 日志使用转义形式，构建脚本不再打印含中文的绝对路径，管线只打印相对脚本名。

图表还有另一项跨平台差异：runner 不一定安装微软雅黑等 CJK 字体。CI 在已提交确定性图表的前提下跳过重新渲染，同时检查图表确实存在；最后用 `git status --porcelain` 确认离线重建没有改变任何受版本控制的文件。相关修复分别记录在 80b9576 和 f05a183。这次排错提醒我先判断故障位于数据、计算、持久化还是展示层，避免为了终端显示问题去改动已经正确的数据逻辑。

三、香港科技大学 IEDA 暑研

3.1 研究动机：从偏好拟合走到下游策略

暑研课题是大模型对齐。第一周我系统学习了 RLHF 和 DPO：RLHF 先从成对偏好训练奖励模型，再利用奖励更新策略；DPO 把隐式奖励写入策略概率比，直接优化偏好目标。两者都离不开偏好数据，却可能面对 reward model 或 policy class 错误[5—8,11—12]。

我的直觉来自数据驱动运筹学中的 Smart Predict-then-Optimize[10]。预测模型在均方误差上更准，不代表由它产生的优化决策更好。迁移到 alignment 后，相应问题

是：一个 reward 在偏好 NLL 上更好，是否一定会诱导更高效用的 policy？如果最终使用者关心的是策略，而不是 reward 本身，就需要按下游 policy regret 评价 reward。

7 月 14 日的第一次汇报从 RLHF、DPO、pair sampling 和 misspecification 展开。我在汇报末提出：在受限 reward class 中，不应只寻找最接近偏好概率的模型，还应关注哪一个 reward 诱导出的可达策略在目标奖励下表现更好。汇报后，我将这个直觉进一步表述为 Prospective Reward Modeling。

3.2 理论推导

我先定义 KL 正则化策略目标 $J(\pi, r)$ ，并把给定 reward r 诱导的最优策略记为 π_r 。reward utility 是 π_r 在目标奖励 r^* 下的表现，policy regret 则比较 π_r 与目标奖励可达最优策略的差距。这个定义把评价对象从“reward 是否拟合标签”转成“reward 通过训练过程会把 policy 推到哪里”。

在参考策略附近作局部二阶展开后，策略移动受 Fisher 矩阵约束，reward 只通过 policy-visible moment 影响更新[9]。由此，局部 regret 可以写成奖励差在相关子空间中的加权二次距离。不会改变局部 policy 更新的 reward 方向属于同一等价类，不应仅因函数值不同而受到等量处罚。

$$\text{Reg_loc}(r) = (1 / 2\beta) \|A(r - r^*)\|^2_{F^\dagger}$$

3.2.1 从双层目标到局部 policy regret

给定参考策略 π_0 和 KL 系数 β ，我使用正则化目标：

$$J(\pi; r) = E[r(x, y)] - \beta E_x[KL(\pi(\cdot|x) \parallel \pi_0(\cdot|x))]$$

由候选奖励 r 诱导的策略记为 $\pi_r \in \arg\max_{\pi} J(\pi; r)$ 。随后用不可观测的目标奖励 r^* 评价该策略，定义 $U\beta(r) = J(\pi_r; r^*)$ ，并令 $\text{Reg}\beta(r) = U\beta(r^*) - U\beta(r)$ 。这里 r 负责选择策略， r^* 负责评价策略，二者不能混为一个对象。这个定义也解释了为何偏好 NLL 不是最终目标：两个 reward 即使对标签的拟合不同，只要诱导出相同的策略移动，下游效用可以相同；反过来，拟合差异很小的 reward 也可能把策略推向不同方向。

为了让双层目标可计算，我在参考参数 θ_0 附近展开策略。令 $d_0(x, y) = \rho(x) \pi_0(y|x)$ ，score 为 $s(x, y) = \nabla \theta \log \pi_\theta(y|x)|_{\theta_0}$ ，并定义 $A_r = E_{d_0}[sr]$ 、 $F = E_{d_0}[ss^T]$ 。 A_r 是 reward 在局部 policy tangent 中可见的一阶矩， F 是参考策略下的 Fisher 矩阵。二阶展开为：

$$J_{\text{loc}}(\theta_0 + \Delta\theta; r) = E_{d_0}[r] + A_r^T \Delta\theta - (\beta/2) \Delta\theta^T F \Delta\theta$$

令梯度为 0，可得 $\Delta\theta_r = (1/\beta)F^\dagger A_r$ 。受限 LoRA 参数化下 F 不一定满秩，所以这里使用伪逆。将候选 reward 和目标 reward 的两个局部最优更新代回目标效用，常数项抵消后得到 $\text{Reg}^{\text{loc}}\beta(r) = (1/(2\beta))(A_r - A^*)^T F^\dagger (A_r - A^*)$ 。原本需要为每个 reward 完整训练 policy 的昂贵双层问题，由此变成 Fisher 加权的 moment 匹配。

这个表达式还给出 reward 等价类。若 $A_{r1} = A_{r2}$ ，两个 reward 在当前参考策略附近诱导同一个更新，即使函数值并不相同，也可以归入同一类。奖励误差中落在 policy 不可见零空间的部分不会进入局部 regret。受限 reward class 无法表示 r^* 时，需要寻找的是可达类中下游效用较高的 reward，而非函数值上最接近 r^* 的 reward。

这组推导也暴露出困难：真实最优策略与目标奖励不可直接观察，完整大模型优化成本很高。因此，第一阶段选择受控的 Synthetic-oracle 设置、线性 reward head 和单步局部策略更新，先验证“拟合排序与下游效用排序可能分离”这一机制。

3.2.2 从偏好概率到可用的 reward margin

成对偏好标签通常只告诉我们回答 y 是否胜过 y' ，但局部 regret 需要的是两个回答的奖励差。在 Bradley-Terry 模型中，偏好 y 的概率为 $q = \sigma(\Delta r)$ ，因此真实 margin 为 $\Delta r = \log(q/(1-q))$ 。若一条回答对获得 N 次重复标注，其中 y 获胜 S 次，最直观的做法是用 S/N 代替 q ，再取 logit。问题是 logit 为非线性函数，即使 S/N 对 q 无偏， $\text{logit}(S/N)$ 也不会对 $\text{logit}(q)$ 无偏；当 $S=0$ 或 $S=N$ 时还会出现无穷大。简单的截断能让训练继续，却会把截断常数人为地带入 reward margin。

有限重复标注组因此使用一个随机标注次数的构造。对每条边 e ，令 $P(N_E = n) = (1-\gamma)\gamma^{n-1}$ 且 $\gamma = 0.9$ ；这等价于成功概率 0.1 的几何分布， $E[N_E] = 10$ 。再在给定 N_E 时令 S_E 服从二项分布。通过下降阶乘可以构造：

$$H_E = \sum_{j=1}^{N_E} [(S_E)_j - (N_E - S_E)_j] / [j \gamma^{j-1} (N_E)_j]$$

这个量在给定回答对 e 时的期望等于真实 margin Δr^*_E 。它的意义不是消除标注噪声；单条边的 H_E 仍然可能方差很大，所以实验中还要使用多条边聚合、阻尼和 cross-fitting。它解决的是更具体的问题：训练目标在期望上对准 reward margin，不因非线性 plug-in 产生系统性偏差。O 组直接使用 Synthetic oracle 提供的精确 Δr^* ，H 组使用 H_E ，两组共享同一个 policy geometry 和后续评价。这样可以分开考察两件事：ProRM 的下游目标是否有用，以及当 reward margin 只能通过有限偏好标注估计时，这一方向是否仍能在描述性结果中保持。

这一构造也说明了为什么实验不把“标注更多”当成唯一答案。重复标注确实可以降低不确定性，但如果最终仍用一个与 policy 决策无关的函数误差训练 reward，更精确的标注也不保证将误差压在 policy-visible 方向上。有限标注估计和下游 regret 目标因此是两个必须分开又需要连接的层次。

Preliminary

$x \in \mathcal{X}$ 表示 prompt $y \sim p$
 $y \in \mathcal{Y}$ 表示输出 $y \sim p(y|x)$
 $\pi_\theta(y|x)$ 表示 LLM 策略
 $\pi_\theta(y|x)$ 表示策略模型

Bradley-Terry 偏好估计

$\pi(y_1 > y_2 | x) = \frac{\pi_\theta(y_1|x)}{\pi_\theta(y_1|x) + \pi_\theta(y_2|x)}$
 $\pi(y_1 < y_2 | x) = \frac{\pi_\theta(y_2|x)}{\pi_\theta(y_1|x) + \pi_\theta(y_2|x)}$

KL 正则策略估计

$J_\pi(\pi) = \mathbb{E}_{x \sim p} \mathbb{E}_{y \sim \pi} [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

闭式解

$\pi^*(y|x) = \pi_\theta(y|x) \exp(\frac{\beta \log \pi(y|x)}{\pi_\theta(y|x)}) / Z_\pi(x)$
 $Z_\pi(x) = \sum_y \pi_\theta(y|x) \exp(\frac{\beta \log \pi(y|x)}{\pi_\theta(y|x)})$
 $\Leftrightarrow \pi(y|x) = \beta \log \frac{\pi(y|x)}{\pi_\theta(y|x)} + \beta \log Z_\pi(x)$
 $\Rightarrow J_\pi(\pi) = \mathbb{E}_x [\beta \log \frac{\pi(y|x)}{\pi_\theta(y|x)} + \beta \log Z_\pi(x)]$
 $\Rightarrow \mathbb{E}_x [\log \pi(y|x)] - \beta \mathbb{E}_x [\log \pi_\theta(y|x)] + \beta \mathbb{E}_x [\log Z_\pi(x)]$
 $\Rightarrow J_\pi(\pi) = J_\pi(\pi_\theta) + \beta \mathbb{E}_x [\log \pi(y|x) - \log \pi_\theta(y|x)]$

RLHF

$R_\pi = \{r_\pi, \theta \in \Theta\}$ $\pi_\theta = \{\pi_\theta, \theta \in \Theta\}$
 $\hat{\pi}_\theta = \{\pi_\theta, \theta \in \Theta\}$
 $\hat{\pi}_\theta = \arg \min_{\pi \in \Pi} \mathbb{E}_{x \sim p} \mathbb{E}_{y \sim \pi} [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$
 $\hat{\pi}_\theta = \arg \min_{\pi \in \Pi} \mathbb{E}_{x \sim p} \mathbb{E}_{y \sim \pi} [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

DPO

$r_\pi(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_\theta(y|x)} \Leftrightarrow \pi_\theta = \pi_\theta \exp(\frac{\beta}{\pi_\theta})$
 $R_\pi = \{r_\pi, \theta \in \Theta\}$
 $\hat{\pi}_\theta = \arg \min_{\pi \in \Pi} \mathbb{E}_{x \sim p} \mathbb{E}_{y \sim \pi} [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$
 $\hat{\pi}_\theta = \arg \min_{\pi \in \Pi} \mathbb{E}_{x \sim p} \mathbb{E}_{y \sim \pi} [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

总结一些量

$\pi_\theta = \{\pi_\theta, \theta \in \Theta\}$
 $R_\pi = \{r_\pi, \theta \in \Theta\}$
 $R_\pi = \{r_\pi, \theta \in \Theta\}$
 $r_\pi \rightarrow \pi^* \in \arg \min_{\pi \in \Pi} J_\pi(\pi) = \pi_\theta \exp(\frac{\beta}{\pi_\theta})$

统一几何解释

1. RLHF

① $\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

② $\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

2. DPO

$\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

从 KL 正则化到局部 policy regret?

数据生成

$\{x_i\}_{i=1}^n, y_i = \{y_{i1}, \dots, y_{iM}\}$ $y_i \sim \pi_\theta(y_i|x_i)$
 $e = (x, y^*, y) \quad y^* \sim \pi_\theta(y|x)$
 $y \sim \text{Bern}(\pi_\theta(y|x))$
 $E = \{y^*, y\} \in \mathcal{Y} \times \mathcal{Y}$
 $E = \frac{1}{2} (y^* + y)$
 $E \sim \mathcal{D} \in \mathcal{E}(E)$ 抽样分布: $\mathcal{D}(\mathcal{E}(E) | E)$

损失函数的等价写法

① 单点

$(x, y^*, y) \sim \mathcal{D}$
 $L(x) = -\log \pi(y^*|x)$
 $L(x) = -\log \pi(y|x)$

② 双点

$e = (x, y^*, y) \sim \mathcal{D}$
 $L(e) = -\log \pi(y^*|x) - \log \pi(y|x)$
 $L(e) = -\log \pi(y^*|x) - \log \pi(y|x)$
 $L(e) = -\log \pi(y^*|x) - \log \pi(y|x)$

③ 抽样分布加权

$L(e) = \sum_{y \in \mathcal{Y}} \pi(y|x) L(e)$
 $\Leftrightarrow \sum_{y \in \mathcal{Y}} \pi(y|x) L(e)$

KL 散度

$D_K(P \| Q) = \mathbb{E}_P [\log \frac{P}{Q}]$
 $I(x) = -\log \pi(x)$
 $H(x) = -\mathbb{E}_x [\log \pi(x)]$
 $H(x, y) = -\mathbb{E}_{x, y} [\log \pi(x, y)]$
 $D_K(P \| Q) = H(P, Q) - H(P)$
 $\text{KL 散度} \Leftrightarrow \text{KL 散度} \Leftrightarrow \text{MLE}$
 $\text{KL 散度} \Leftrightarrow \text{KL 散度} \Leftrightarrow \text{MLE}$

统一几何解释

1. RLHF

① $\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

② $\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

2. DPO

$\arg \min_{\pi \in \Pi} \mathbb{E}_x [\pi(y|x) \log \frac{\pi(y|x)}{\pi_\theta(y|x)}]$

从 KL 正则化到局部 policy regret?

图 3 暑研第二周手写推导节选：从 RLHF/DPO 到局部 policy regret

3.3 HPC4 实验设计与实现

实验在 HKUST HPC4 平台运行，使用 4 张 L20 48GB GPU。参考 policy 为 Qwen2.5-1.5B-Instruct，目标 reward 使用 Skywork-Reward-V2-Llama-3.2-3B。MultiPref 数据共有 4,608 个 prompts，划分为 3,072 个训练、512 个验证、512 个正式

测试和 512 个诊断 prompts；每个 prompt 生成 6 个候选回答，对应 15 条 comparison edges[15—17]。

为控制比较，reward 侧冻结 Qwen 的 1536 维表示，只训练无偏置线性头；policy 侧只使用最后一层 q_proj/v_proj 的 rank-4 LoRA-B，形成 7168 维局部 tangent。Fisher 由节点 score 估计，reward moment 由 pair edge 统计估计；训练集内五折 cross-fitting 用于固定相对阻尼 $\lambda_{rel}=10$ ，结果表中的近似 regret 则在正式测试集上使用两折 cross-product 估计。所有方法使用 $\beta=0.2$ 的单步 natural-gradient 更新。

组件	冻结设置	目的
数据	4,608 prompts；每个 6 候选、15 条边	统一 pair 与测试单位
Reward	冻结 1536 维表示，只训练线性头	控制 reward class
Policy	最后一层 rank-4 LoRA-B	控制局部 policy tangent
更新	$\beta=0.2$ ，单步 natural gradient	统一 β 与单步更新规则
评价	512 held-out prompts×6 fresh responses	评价更新后重新采样的回答

实验比较两类训练信号。O 组直接使用目标 reward 差，H 组使用有限重复的偏好标签；每类信号都训练 MLE、MSE 和 Pro 三种 reward head，另设 direct oracle 和不更新的 reference，共 8 个 policy pipeline。正式实验使用三个独立随机种子。每个更新后的 policy 都在 held-out prompts 上重新生成回答，而不是复用训练样本。

3.3.1 从公式到 HPC4 实现

实现时，我把每个 prompt 的 6 个回答看作节点，把 15 个无序回答对看作边。节点 $v=(x,y)$ 提供 score s_v ，用节点平均估计 F ；边 $e=(x,y,y')$ 提供 Δs_e 和 reward margin Δr_e ，用边平均估计 A_r 。F 描述单个回答处的策略几何， A_r 则需要比较两个回答对策略方向的相对推动，两者的统计单位不能混为一张表。

有限重复偏好标签也不能直接用经验胜率 S_e/N_e 替代 reward margin，因为 Bradley–Terry 模型给出 $q^*_e=\sigma(\Delta r^*_e)$ ，概率与 logit margin 不是同一量。实验令 N_e 服从成功概率 0.1 的几何分布（等价地记尾概率参数 $\gamma=0.9$ ， $E[N_e]=10$ ），并在给定 N_e 后令 S_e 服从二项分布；再利用下降阶乘构造无偏 margin 估计 H_e ，使 $E[H_e|e]=\Delta r^*_e$ 。O 组直接使用目标 reward 的精确 margin，H 组使用有限重复标注估计量。这样的分组把两个问题分开：训练目标本身是否正确，以及标签噪声是否破坏目标方向。

reward 端冻结 1536 维表示，只训练无偏置线性头 $r_w = h^T w$ 。若 $G = E_{do}[sh^T]$ ，则 $A_r = Gw$ ，ProRM 对应的线性系统为：

$$G^T F \lambda^{-1} G w = G^T F \lambda^{-1} A^*$$

7168×7168 的 Fisher 矩阵没有被显式构造或求逆。我使用 PCG 计算 $F \lambda^{-1} v$ 形式的逆向量乘积，再求解线性头的正规方程。相对阻尼 $\lambda_{rel}=10$ 由训练集内五折 cross-fitting 固定；正式测试集上的近似 regret 采用两折 cross-product，避免用同一批测试样本作自乘而产生偏差。有限样本估计可能为负，汇总时不人为截断为 0。policy 更新统一为 $\beta=0.2$ 的单步 natural gradient，只作用于最后一层 q_{proj}/v_{proj} 的 rank-4 LoRA-B，使 8 条 pipeline 采用相同的受限 policy class、 β 和正则化系数。

正式评价没有复用训练回答。每个随机种子、每条 policy 都在 512 个 held-out prompts 上重新生成 6 个回答，因此总量为 $3 \times 8 \times 512 \times 6 = 73,728$ 。policy 评价中的 R 是目标 reward 均值，K 是相对参考策略的 forward KL， $J = R - 0.2K$ 。把 reward fit 表与 policy 表分开保留，是为了防止在看到一项指标后选择性解释另一项。

3.3.2 从试跑到正式三种子的冻结过程

HPC4 上的首次运行目标不是立即生成最终表格，而是检查一条从数据到策略的长依赖链是否真正连通。管线依次需要完成 prompt 切分、候选回答物化、pair 边构造、score 提取、Fisher 与 moment 估计、reward head 求解、LoRA 参数写回、策略更新、fresh response 生成和目标 reward 评价。其中任何一步的 prompt 索引错位，都可能在形状上完全正常，却使边上的 reward margin 对应到错误回答。因此试跑阶段首先对每个 prompt 的 6 个节点和 15 条无序边做数量对账，再抽查回答索引、标签方向与差分 score 的符号。

Fisher 相关步骤的困难是规模和数值稳定性。7168 维局部参数使得显式构造稠密矩阵既占内存，又会放大近零特征方向的误差。PCG 实现因此不保存 F 的逆，只提供一个输入向量到 F 乘积的算子，并通过相对阻尼抑制不稳定方向。试跑时不只检查求解器是否结束，还记录残差、迭代次数和参数移动大小。如果求解器得到很小的线性残差，却产生异常大的 KL，问题就不应被归结为“训练更有效”，而应返回检查阻尼、score 尺度和 LoRA 写回。

评价链条也设有明确的泄漏检查。训练 prompts、验证 prompts、正式 test prompts 和诊断 prompts 在数据物化前就分开；Fisher 由 train nodes 估计，训练集内五

折只用于选择相对阻尼 λ_{rel} ，正式 test 上的近似 regret 由两折 cross-product 估计；policy 评价则不使用已经用来训练 reward 的回答，而是在 held-out prompts 上重新采样 fresh responses。每条记录保留 seed、pipeline、prompt id 和 response id，聚合前先验证每个组合都有 512×6 条。如此，73,728 不只是一个最终总数，还能拆回三个 seed、八条 pipeline 和每条 pipeline 的 3,072 个新回答。

小规模试跑通过后，正式实验才冻结随机种子 20261001、20261002 和 20261003、 $\beta=0.2$ 、相对阻尼 10、reward 表示、LoRA 范围、数据切分和生成数量。方法比较中，O 与 H 只改变目标 reward margin 的获取方式，MLE、MSE 和 Pro 共享相同的表示、policy class 与更新预算。这种冻结是为了让最终排序尽量对应训练目标差异，而不是不同方法各自选择有利的训练强度。每个 seed 的 reward fit、局部 regret、目标 reward、KL 与 policy J 都先单独保留，之后才计算均值和样本标准差。

完成标准不是某一条 pipeline 首次返回数值，而是八条 pipeline 在三个种子上都有完整训练、更新和重新生成记录，总数与理论乘积一致，评价表可以从 rollout 重新聚合，并且配置、运行日志和最终报告相互对应。这一组验收使实验的“完成”具有可检查含义，也是第四周能够将理论、实验、结果和答辩一起收口的基础。

3.4 结果与解释

三随机种子共生成 73,728 条 fresh rollout。以下数字均为三种子均值，括号内为样本标准差。Direct oracle 的 policy J 为 0.02334 (0.01649)，reference 为 0.00388 (0.01016)。O 组中，O-Pro 为 0.02068 (0.01837)，O-MSE 为 0.01721 (0.01348)，O-MLE 为 0.01599 (0.00960)；H 组中，H-Pro 为 0.02000 (0.01729)，H-MLE 为 0.01768 (0.00817)，H-MSE 为 0.01728 (0.01042)。H-Pro 与 O-Pro 点均值相差约 6.83×10^{-4} ，但种子间波动明显大于该差值，不能据此声称统计等价或显著接近。

Pipeline	Policy J (均值±样本标准差)	近似 regret (均值±样本标准差)	观察
Direct oracle	0.02334±0.01649	—	理想信号参照，仍受局部单步设置限制
O-Pro	0.02068±0.01837	0.00016±0.01877	三种子均值上精确信号组内最高 J
O-MSE / O-MLE	0.01721±0.01348 / 0.01599±0.00960	0.00469±0.00323 / 0.00612±0.00255	拟合基线
H-Pro	0.02000±0.01729	0.00503±0.01052	三种子均值上有限标签组内最高 J

Pipeline	Policy J (均值±样本标准差)	近似 regret (均值±样本标准差)	观察
H-MSE / H-MLE	0.01728±0.01042 / 0.01768±0.00817	0.00645±0.00465 / 0.00963±0.00590	有限标签基线
Reference	0.00388±0.01016	—	未更新策略

值得关注的是，O-Pro 的 NLL 和 MSE 并不是组内最好，但三种子均值上的局部 regret 最低、policy J 最高。当前实验因此观察到 reward fit 与下游评价的排序分离，支持继续研究按 policy regret 训练 reward。H-Pro 和 O-Pro 的点均值接近只能作为数值现象记录；三个种子不足以判断两者等价，也不能量化有限重复标注保留了多少目标信息。

这些结果不应被夸大对所有 RLHF 场景的普遍结论。实验只包含三个种子，使用 Synthetic oracle、冻结表示、线性 reward head、rank-4 LoRA、局部二阶近似和单步更新。第一阶段已经完成理论对象估计、端到端训练和 fresh-rollout 评价；三种子均值上出现的排序分离属于机制证据。真人偏好、更大模型、多轮 PPO 和分布偏移仍需要新的研究。

3.4.1 如何解读三种子结果

结果表中有两种完全不同的排序。reward-fit 排序回答“哪个线性头更能拟合当前 pair 标签或 margin”；policy 排序回答“用这个 reward 完成同一次局部更新后，新策略在目标 reward 与 KL 权衡下的得分如何”。O-Pro 的 NLL 和 MSE 比 O-MLE 与 O-MSE 差，却在三种子均值上得到更高的 J 和更低的局部 regret。这一现象没有否定 reward fit 指标的作用：它们仍然能发现标签过拟合、训练失败或数据问题。它支持的更限定性结论是，在当前受限 policy class 中，拟合指标不能单独代替下游策略评价。

样本标准差在这里同样重要。O-Pro 与 H-Pro 的 J 均值差只有约 6.83×10^{-4} ，但两者跨 seed 的样本标准差均在 0.017 以上，远大于均值差。因此不能说有限重复标注与精确信号“等价”，也不能把两个均值近似解释为 H 保留了某一确定比例的目标信息。目前可以陈述的是，H-Pro 在三个种子的点均值上没有出现明显崩塌，并在 H 组内取得最高 J；要比较两类信号的差异，仍需要更多 seed 和预先确定的统计检验。

Direct oracle 在表中只是理想信号参照，不是对所有训练方法的理论上界。它仍受制于同一个局部 LoRA 空间、单步更新、有限生成样本和目标 reward 噪声。

Reference 则提供不更新时的基准。将它们放在同一张 policy 表中，可以判断某个方法是否只在 reward 拟合上改善，还是真的产生了高于未更新策略的新回答分布。这也是最终报告同时保留 fit、regret、R、KL 和 J 而不只展示单一胜负数字的原因。

3.5 暑研完成情况

截至 8 月初，暑研第一阶段的预定任务均已完成。学习与文献阶段形成《Preference Learning: RLHF & DPO》汇报；理论阶段完成 reward utility、exact/local regret、Fisher 几何与奖励等价类推导；实验阶段完成固定配置下的三随机种子、8 个 policy pipeline 和 73,728 条 rollout；最后整理为《Prospective Reward Modeling》报告并完成答辩。

后续真实 policy、真人偏好和更大模型实验属于研究延伸。把它们列为未来工作，是因为第一阶段已经按预定范围完成机制验证并给出机制证据，而不是因为暑研未完成。区分“阶段完成”和“研究终止”也让我更准确地表达科研进度。

四、实践中的问题处理与交付整理

4.1 数据能下载，不等于能使用

逐球文件缺少一条球种标签只是最直观的问题。更隐蔽的风险来自分母：如果把全部投球当作 Whiff% 的分母，挥空能力会被系统低估；如果用逐球记录重建 K 和 BB 却不与比赛日志核对，自动事件可能造成误差。解决这些问题并不需要复杂模型，而需要耐心记录数据层次和对账关系。此后我每加入一个指标，都会先写清分析单位和校验来源。

4.2 一个顺畅故事往往缺少反例

“高 ERA—球威下降—转牛棚”是一条很顺畅的叙事，但 K%、Whiff、球速、牛棚小样本和第三轮结果都对它提出反例。我起初担心加入这些限制会削弱结论，后来发现它们反而把建议变得更具体：短期牛棚可以保留，但必须设置观察门槛；变速球值得重建，但不能用 29 球证明它已适应 MLB；四缝线需要调整，但重点是左打情境。

港科实验也出现相同问题。如果只报告 reward NLL，实验很容易结束在代理指标上。让更新后的 policy 重新生成回答，工作量更大，却真正检验了研究命题。今后面对一个看似漂亮的结果，我会先问它是否走到了最终评价对象。

4.3 技术结果需要翻译成行动

图表和模型本身不会自动产生决策。把 Zone%、首球、BB 和变速球结构写成 3—4 周校准、60 打席门槛和 45—60—75 球阶梯时，我需要区分“数据直接告诉我的”和“我根据数据制定的管理规则”。前者要准确，后者要透明并允许更新。这种翻译能力是本次实践中最接近真实工作的一部分。

4.4 从分析结果到可提交材料

同一项研究在不同受众面前需要不同层级的信息。老师需要判断我是否完成了从问题设定到复现的全过程，所以实习报告保留数据口径、理论推导、实验配置、反证和参考文献。单位审阅者更关心“当前怎么判断、下一步谁做什么、什么情况下停止”，所以两页汇总先给结论和行动表，再用一张图保留最必要的证据。计算细节、来源字典、分析迭代和复现方法另分成四份底稿，让审阅者在需要时可以继续下钻，而不必在第一页阅读所有分母。

文档排版也按任务区分。MLB 课程的两页决策稿要求 A4 两面以内、小五微软雅黑且第一段论点加粗，因此该稿不使用封面、装饰色块或大量图表，只用黑字、浅灰表头和一张统计图。本实习报告则使用宋体小四、1.5 倍行距和黑体分级标题，保证长文阅读与学校书面材料一致。表格只用在数值映射、阶段比较或责任分工，不再用表格模仿章节标题和提示框。图题、表头、页码、边距和分页均在同一构建脚本中固定，防止不同文档随手修改后出现字体与尺寸漂移。

项目按固定清单完成三轮检查并保留机器记录。第一轮由脚本重算 17 份原始快照的 SHA-256，并核对 1,240 个带球种标签投球、80 次三振、42 次保送和 17 场比赛；第二轮检查 Word 的 A4 尺寸、页码、表格、图题和个人信息；第三轮由文档工具导出 PDF 和逐页图片，逐页初检标题孤行、跨页表格、图片裁切、字体替换和异常留白。两页稿的页数只在实际渲染后认定，最终提交版本仍由我对核心事实、结论边界和个人信息作确认。

跨材料核对时，我另外建立了“事实—解释—行动”三列检查顺序。17 场、288 个打席、1,241 条原始逐球记录和 1,240 个带球种标签投球属于事实，必须在周记录、报告和底稿中完全一致；“牛棚方向积极但不能作因果判断”属于解释，必须始终带着 23 个打席和混杂因素；先积累 60 个打席、滚动窗口、46%、60%和 10%则属于我

提出的管理规则，必须写明设置依据与退回条件。这样检查能够避免把同一个百分比在一份材料中写成观察结果、在另一份材料中又写成自然阈值。

一次具体修订来自局数口径。StatsAPI 使用棒球记分法记录 64.2 局，它不是十进制的 64.2 局，而是 64 局加两个出局数。若直接用于 ERA 计算，分母会产生系统误差。我先把它换算为 194 个出局数，再在所有面向读者的文稿中写成 64 又 2/3 局，并在口径底稿保留官方原写法。这个问题没有改变结论，却提醒我：格式看似熟悉并不代表可以跳过定义，尤其是在跨来源数据合并时。

文档之间也没有追求逐字相同。教师端报告需要呈现学习、推导、反证和反思，因此保留方法细节与港科暑研；单位端两页稿只回答当前判断、短期动作、升级条件和失败处理；四份底稿分别承担完整论证、数据口径、判断迭代和复现核查。通过这种分工，同一证据可以保持口径一致，又不会让不同收件人重复阅读同一段长解释。

仓库复现还需要考虑新环境。Windows 上的换行转换可能使原始 HTML 的字节哈希在新 clone 中失配，因此.gitattributes 对 data/raw 按二进制字节保留；构建产物清单排除__pycache__与 pyc，避免把本机临时缓存当成研究成果；默认流水线不联网，从已跟踪的 raw 快照重算，防止 CI 由于赛季页更新而无法复现提交时的结论。只有这三层状态对应到具体证据，仓库和 Word 材料才能一起被称为可交付，而不是仅仅拥有一份看起来完成的报告。

五、收获、不足与后续计划

5.1 对数据分析的认识

我过去容易把数据分析理解为“找到数据、选择模型、输出结果”。本次实践让我看到，真正耗时的是确定问题、固定口径和处理反例。一个能复现的数字还不等于一个可靠的结论；结论还需要适当的比较对象、样本边界和替代解释。只有这些条件清楚，建议才不会随一次结果波动而改变。

MLB 项目也让我更熟悉公开数据工程。原始快照、处理表、配置、脚本、图表和报告需要使用同一截止日；修改某一环后，应重算它影响的下游，而不是只替换 Word 中的数字。Git 和自动检查在这里不是形式，而是帮助我发现数据与叙述不一致的工具。

5.2 研究能力的变化

港科暑假提高了我把直觉写成数学对象的能力。Smart Predict-then-Optimize 的类比起初只是一个想法，只有在定义 reward utility、policy regret、Fisher 和 moment 之后，才变成可以实现的实验目标。HPC4 实验又迫使我面对理论与工程的接口，例如训练数据和评价数据如何分离、Fisher 如何估计、policy 更新后为何必须 fresh rollout。

我也更加重视完成条件。一个研究阶段可以在仍有未来问题的情况下完整结束，只要研究问题、方法、实验、结果、限制和答辩都已完成。相反，代码跑完但没有下游评价或结果边界，并不能算完成。

5.3 仍需改进的地方

棒球项目的主要限制是缺少球队内部信息。公开 Statcast 不能提供完整的健康评估、训练动作、握法和教练意图，现有门槛只能作为外部分析建议。下一步若获得新比赛数据，我会前瞻检验 60 打席和负荷阶梯是否有用，并补充更细的释放点、球形与位置分布分析。

ProRM 仍需验证外部有效性。三个 Synthetic-oracle 种子提供的是机制证据，不能代替真人偏好、真实策略分布、更大模型和多轮优化。后续研究应先保持评价口径不变，再逐步放宽 reward class 和 policy class，避免同时改变太多环节而无法解释结果。

写作方面，我还需要继续减少过度压缩。技术内容集中时，我容易在一句话中放入过多指标和限定，读者很难抓住主线。在两页决策稿中，我把主体改为“当前判断—短期动作—升级条件—失败处理”，精确分母和限制则留在表注与底稿。这种层级划分比单纯删减文字更有用，因为它保留了快速阅读和深入复核两种入口。

5.4 三个具体工作片段

第一个片段是处理无球种标签的自动坏球。当时最直接的选择是删掉这一行，这样球种表与图很快就能对齐。但删除后，“原始逐球数”和“有球种标签的投球数”会被写成同一个数，后来的人也无法知道曾经存在异常。另一个选择是根据前后球猜测它的球种，但自动坏球并不保证有实际投球，这种填补会制造原数据中不存在的信息。最终采用的办法是保留完整原始文件，对球种聚合明确排除该行，并在对账表和报告中分别写 1,241 与 1,240。这一决定没有改变主要结论，却使整条证据链可

以解释。它也让我理解，数据清洗不是让所有表格看起来完美，而是对信息缺失做可追踪的决定。

第二个片段是修改对牛棚的判断。初次看分组表时，`Zone%`、首球好球率和`Whiff%`三项都向好，很容易写成“转后援后表现提升”。继续拆分后，我发现这一结论依赖仅 89 球和 23 个打席，牛棚 `Zone%` 的区间足以覆盖很多可能的真实水平；同时，四缝线均速并没有因任务变短而提高，角色转换与伤情恢复、日期趋势交叠。这些反例迫使结论从“后援更适合”改为“牛棚是当前有价值的校准环境”。前一种说法直接决定长期角色，后一种说法则要求扩大样本、设定过程门槛并逐步增加负荷。正是这一修改，使最终建议从一句角色判断变成可以被新比赛验证的路线。

第三个片段发生在港科实验的评价环节。`reward head` 训练完成后，最省计算的办法是直接已在已有候选回答上报告 `NLL`、`MSE` 或 `reward` 排序，但这样无法回答研究问题：这个 `reward` 究竟会把 `policy` 更新到哪里。因此，正式管线为每个 `reward` 完成同一局部策略更新，再让更新后的 `policy` 在未参与 `reward` 训练的 `prompts` 上重新生成回答。这一选择把正式评价规模增加到 73,728 条 `rollout`，也带来显存、作业排队、随机性和结果聚合的额外工作。但只有走完这一步，才能同时看到目标 `reward` 收益和 `KL` 成本，也才能发现 `O-Pro` 在拟合指标上并不占优，却在三种子均值上获得更高策略效用的排序分离。这个片段使我更清楚地认识到，评价设计不是训练之后的附属报表，而是研究问题本身的一部分。

5.5 指标与决策之间的共同问题

`MLB` 项目与 `ProRM` 研究表面上相距很远，实际都暴露了代理指标和最终任务之间的距离。`ERA` 可以概括已经发生的失分，却不能直接决定投手应继续先发还是转入牛棚；`reward NLL` 可以概括偏好拟合，却不能直接说明更新后的 `policy` 是否更好。我在两个项目中都先明确最终需要回答的问题，再回头选择指标：`MLB` 项目的终点是角色调整的条件，`ProRM` 的终点是目标奖励下的正则化 `policy utility`。这个顺序改变了我处理数据的方式。

我过去看到一个异常值时，习惯先判断它是否“合理”；这次更重要的问题是它来自哪一层数据、采用什么分母、能否由另一来源核对。64.2 局的记分方式、一条无球种标签的自动坏球、牛棚 23 个打席的宽区间，单独看都只是小问题，却会影响

后续论证。港科实验中的节点、边和 fresh rollout 也是同样的道理：训练样本、moment 估计单位和最终评价样本一旦混用，再漂亮的结果也难以解释。

我也更清楚地区分数据结果与研究者规则。K%、BB%、Zone%及其区间来自冻结样本；60 个打席、滚动窗口、Zone%不低于 46%和 45—60—75 球阶梯是便于执行的管理标准，并非模型估计的自然分界点，球队应按健康状况和新增比赛更新。ProRM 中的 β 、LoRA 范围和单步更新同样只是机制实验的控制条件，不是对真实 RLHF 训练的永久设定。

跨平台编码失败进一步改变了我对“完成”的理解。一个项目在作者电脑上跑通，只能说明局部环境没有暴露问题；原始数据冻结、处理步骤可重算、终端环境可兼容、输出文件字节稳定、结论能够回到具体表格，合在一起才形成可交付成果。今后无论处理体育数据还是模型实验，我都会保留这条检查链，同时把反例和不确定性放进正文，而不是留到答辩追问时再补充。

六、结语

这次短学期实践让我完成了两种不同但相互呼应的工作。MLB 项目从一项开放课程题目出发，最终形成有数据、有反证、有门槛的角色调整方案；港科暑研从 RLHF 和 DPO 学习出发，完成了 Prospective Reward Modeling 的理论推导、机制实验和答辩。两项工作都提醒我：代理指标只是工具，最终必须回到真实决策或策略效用。

比最终数字更重要的，是我逐渐建立了自己的工作顺序：先说明要做什么决定，再确定数据和评价口径；看到结果后主动寻找反例；写建议时把事实、判断和限制分开；提交前让数据、代码和文稿相互核对。这个顺序仍会在后续项目中继续调整，但已经成为本次实践最有价值的收获。

参考文献

1. Major League Baseball. MLB Stats API: Tatsuya Imai 2026 Pitching Game Log[DB/OL]. <https://statsapi.mlb.com/api/v1/people/837227/stats?stats=gameLog&group=pitching&season=2026>（访问日期：2026-08-14）。
2. Major League Baseball. Baseball Savant: Tatsuya Imai Statcast and Pitch Arsenal Data[DB/OL]. <https://baseballsavant.mlb.com/savant-player/tatsuya-imai-837227>（访问日期：2026-08-14）。

3. Nippon Professional Baseball. 今井達也選手个人成绩[DB/OL].
<https://npb.jp/bis/players/31335134.html>（访问日期：2026-08-14）.
4. NPB Basement. NPB Advanced Pitching and Pitch-Type Database[DB/OL].
<https://npbbasement.com/>（访问日期：2026-08-14）.
5. Bradley, R. A., & Terry, M. E. Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons[J]. *Biometrika*, 1952, 39(3/4): 324—345.
6. Christiano, P. F., Leike, J., Brown, T., et al. Deep Reinforcement Learning from Human Preferences[C]//Advances in Neural Information Processing Systems. 2017, 30.
7. Ouyang, L., Wu, J., Jiang, X., et al. Training Language Models to Follow Instructions with Human Feedback[C]//Advances in Neural Information Processing Systems. 2022, 35: 27730—27744.
8. Rafailov, R., Sharma, A., Mitchell, E., et al. Direct Preference Optimization: Your Language Model Is Secretly a Reward Model[C]//Advances in Neural Information Processing Systems. 2023, 36.
9. Amari, S.-i. Information Geometry and Its Applications[M]. Springer, 2016.
10. Elmachoub, A. N., & Grigas, P. Smart “Predict, then Optimize”[J]. *Management Science*, 2022, 68(1): 9—26.
11. Nika, A., Mandal, D., Kamalaruban, P., et al. Reward Model Learning vs. Direct Policy Optimization: A Comparative Analysis of Learning from Human Preferences[C]//Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024, 235: 38145—38186.
12. Gopalan, A., Ray Chowdhury, S., & Banerjee, D. Why DPO Is a Misspecified Estimator and How to Fix It[EB/OL]. arXiv:2510.20413, 2025.
<https://arxiv.org/abs/2510.20413>（访问日期：2026-08-21）.
13. Major League Baseball. Tatsuya Imai adjusting to pitching in Major Leagues[EB/OL]. 2026-05-31. <https://www.mlb.com/astros/news/tatsuya-imai-adjusting-to-pitching-in-major-leagues>（访问日期：2026-08-14）.
14. Major League Baseball. Tatsuya Imai moved to Astros bullpen[EB/OL]. 2026-07-31.
<https://www.mlb.com/astros/news/tatsuya-imai-moved-to-astros-bullpen>（访问日期：2026-08-14）.
15. Allen Institute for AI. MultiPref Dataset Card[DB/OL].
<https://huggingface.co/datasets/allenai/multipref>（访问日期：2026-08-21）.
16. Qwen Team. Qwen2.5-1.5B-Instruct Model Card[DB/OL].
<https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>（访问日期：2026-08-21）.
17. Skywork Team. Skywork-Reward-V2-Llama-3.2-3B Model Card[DB/OL].
<https://huggingface.co/Skywork/Skywork-Reward-V2-Llama-3.2-3B>（访问日期：2026-08-21）.

附录：主要材料与复现入口

MLB 项目的主要公开来源包括 MLB StatsAPI、Baseball Savant Statcast Search、Expected Statistics、Pitch Arsenal、NPB 官方球员页、NPB Basement，以及用于确认角色背景的 MLB.com 报道。完整 URL、下载时间、文件名和 SHA-256 保存在 MLB-Analytics 项目的数据清单中；核心处理表包括球种、左右打、球数、角色和面对打线轮次分组。

港科暑研的主要个人材料包括 7 月 14 日《Preference Learning: RLHF & DPO》汇报、Prospective Reward Modeling 手写推导、8 月最终答辩《Pre.pdf》和第一阶段实验报告《report111.pdf》。报告中的实验配置与数值均以最终答辩和第一阶段报告为准。