

底稿 02 数据来源与指标口径

今井达也 MLB 调整决策 | 数据截止 2026 年 8 月 12 日

杨炎新 (3230102355) | MLBAM ID 837227 | 17 份原始快照 | 版本 9c8033d

一、这份底稿记录什么

本稿只记录数据来源、字段口径、处理血缘和更新条件，不重复结论或行动建议。分析窗口为 2026 年 3 月 29 日至 8 月 12 日；原始文件于 8 月 14 日下载，因此“下载时间”不等于“数据截止日”。每份文件的 URL、下载时间、字节数和 SHA-256 均登记在 `data/raw/source_manifest.csv`，原始快照不经手工改写。

主分析脚本 `analyze.py` 直接读取 4 份 raw：StatsAPI 比赛日志、Statcast 逐球、Savant Expected Statistics 和 Savant Pitch Arsenal。跨联盟部分还读取两份已经冻结的 NPB 处理表：`npb_basement_imai_advanced_pitching_2023_2025.csv` 和 `npb_basement_imai_pitch_values_2023_2025.csv`。其余 raw 并非都参加计算，有些只负责在联网刷新时重建处理表，有些只作为背景和审计留存。

比赛日志、打席和逐球是三个分析单位。比赛日志负责场次、角色、局数和官方结果；打席用于 K%、BB%和首球指标；逐球用于球种、球数、挥棒、进区、打者侧别和面对打线轮次。64.2 局是棒球记分法，表示 64 局加 2 个出局数。脚本先换算为 194 个出局数，再计算 ERA，不能把 64.2 当成十进制数。

二、17 份原始快照用途台账

下表的“计算使用”指 `analyze.py` 直接读取；“刷新依赖”指 `fetch_data.py --refresh-data` 用来生成 NPB 处理表或发现年度数据模块；“背景留存”指保留网页或榜单作语境、人工核查和后续扩展，当前主计算不读取。

序	raw 文件	分类	当前用途
1	<code>statcast_imai_2026.csv</code>	计算使用	1,241 条原始记录；逐球指标、球种使用、分组和重算 RV 的基础
2	<code>mlb_statsapi_game_log_2026.json</code>	计算使用	17 场日志；角色、出局数、打者数、K、BB、自责分和 ERA
3	<code>npb_imai_player_page.html</code>	刷新依赖	生成 2018—2025 年 NPB 官方传统统计表；当前主脚本不直接读取
4	<code>savant_imai_player_page.html</code>	背景留存	Savant 球员页快照，供球员身份和网页展示信息复核
5	<code>mlb_imai_player_page.html</code>	背景留存	MLB 球员页快照，供名单和基本资料复核
6	<code>mlb_imai_adjustment_article_2026-05-31.html</code>	背景留存	适应过程的时间语境，不替代统计证据

序	raw 文件	分类	当前用途
7	mlb_imai_bullpen_article_2026-07-31.html	背景留存	转入牛棚的时间语境，不用于估计角色效果
8	savant_expected_stats_pitchers_2026.csv	计算使用	按 player_id 筛选今井；当前只读取 xera 字段
9	savant_pitch_arsenal_stats_2026.csv	计算使用	球种级官方 RV、RV/100、wOBA、xwOBA、Hard-hit%，并核对总球数
10	savant_percentile_rankings_2026.csv	背景留存	百分位榜单快照；当前主脚本未读取
11	savant_pitch_movement_ff_2026.csv	背景留存	四缝线位移榜单快照；当前主脚本未读取
12	savant_pitch_movement_sl_2026.csv	背景留存	滑球位移榜单快照；当前主脚本未读取
13	npb_basement_home.html	刷新依赖	发现 NPB Basement 应用脚本的实际文件名
14	npb_basement_app.js	刷新依赖	发现 2023、2024、2025 年度一军数据模块
15	npb_basement_2023_1g.js	刷新依赖	提取今井 2023 年高级、球种和挥棒纪律数据
16	npb_basement_2024_1g.js	刷新依赖	提取今井 2024 年高级、球种和挥棒纪律数据
17	npb_basement_2025_1g.js	刷新依赖	提取今井 2025 年高级、球种和挥棒纪律数据

第 3 项生成 NPB 官方传统统计表，第 13—17 项生成三类 NPB Basement CSV 和一份 JSON。主分析只读取其中的高级投球表与球种价值表；官方传统统计表、挥棒纪律表和完整 JSON 留作核查，不写成“参加了主计算”。

三、清洗、事件集合与分母

Statcast 快照共 1,241 行。其中 1 条是第 7 球的 automatic_ball，没有 pitch_type。该行保留在 raw 中，但球种和逐球主分析只使用其余 1,240 行；它不是首球，所以 288 个打席的首球仍全部保留。K、BB 和面对打者数取自 StatsAPI，不靠删除后的逐球表反推。

代码中的事件集合固定如下：

- Swing 包括 swinging_strike、swinging_strike_blocked、foul、foul_tip、hit_into_play、foul_bunt、missed_bunt。
- Whiff 包括 swinging_strike、swinging_strike_blocked、foul_tip、missed_bunt，是 Swing 的子集。
- Ball 包括 ball、blocked_ball、hit_by_pitch、automatic_ball、pitchout。
- 首球好球要求 pitch_number=1，且 description 不属于 Ball。本样本 149 次成功由 78 次 called_strike、23 次 swinging_strike、31 次 foul、16 次 hit_into_play 和 1 次 foul_bunt 组成；分母是 288 个打席的第一球。
- Zone 指 zone 取 1 至 9；区外球指 zone 非空且不在 1 至 9。本冻结样本中 541 球进区、699 球在区外，两者合计 1,240 球。
- Chase 指区外球同时属于 Swing。因此追打率分母是 699 个区外球，不是总投球数或总挥棒数。

指标	本样本计算	数值	主要落盘位置
----	-------	----	--------

指标	本样本计算	数值	主要落盘位置
K%	80 K / 288 BF	27.8%	analysis_summary.json; 跨联盟 outcomes 表
BB%	42 BB / 288 BF	14.6%	analysis_summary.json; 跨联盟 outcomes 表
K-BB%	(80-42) / 288 BF	13.2%	npb_2025_vs_mlb_2026_outcomes.csv ; analysis_summary.json 没有该字段
Zone%	541 / 1,240	43.6%	总览、角色、球种、侧别、球数和轮次表
首球好球率	149 / 288	51.7%	总览及角色表
Whiff%	175 次 Whiff / 542 次 Swing	32.3%	总览、角色、球种和侧别表
Chase%	190 次 Chase / 699 个区外球	27.2%	总览、角色和侧别表
Usage%	某球种球数 / 1,240	见球种表	mlb_pitch_type_summary.csv
重算 RV/100	$\Sigma \text{delta_pitcher_run_exp} / \text{球数} \times 100$	分组计算	球种、侧别和球数表; 正值对投手有利

角色由 StatsAPI 逐场记录确定：当场 gamesStarted=1 记为先发，其余出场记为牛棚。打者侧别使用 stand；球数分组使用投球前的 balls 和 strikes；面对打线轮次只在先发场次内按 n_thruorder_pitcher 分组。角色、侧别、球数和轮次比较都是观察性描述。角色表中的 Zone、首球、Whiff 和 Chase 另报 Wilson 95% 区间，小样本不会因给出区间而变成稳定估计。

qa/data_reconciliation.csv 把 1,240 个带标签投球、80 次三振、42 次保送和 17 场比赛分别与 Savant Arsenal 或 StatsAPI 核对，四项差值均为 0。差值为 0 只说明数据闭合，不表示研究结论已经得到因果验证。

四、跨联盟字段边界

Expected Statistics 文件在当前脚本中只提供 MLB xERA (4.89)。MLB ERA 由 StatsAPI 的自责分和 194 个出局数重算；K% 和 BB% 也来自 StatsAPI。不能把 Expected 文件笼统写成 ERA、K% 和 BB% 的共同来源。

NPB 2025 年的 K%、BB% 和 K-BB% 来自冻结的 NPB Basement 高级投球表。NPB 官方处理表中可核对到 ERA 1.92，但 analyze.py 目前在跨联盟 outcomes 表内直接写入常数 1.92，没有在运行时读取该 CSV 字段。当前冻结值彼此一致；若参考年份或数据窗口变化，NPB ERA 必须单独人工核对，不能假定刷新后会自动改动。

NPB Basement 与 Statcast 的球种标签、识别模型和比赛环境不同，CH 与 FS 不能视为跨联盟一一对应。为检查结论是否只由标签迁移造成，另把 CH 和 FS 合并核对：NPB 2025 为 12.67%+4.37%=17.04% (17.0%)，MLB 2026 为 2.34%+3.39%=5.73% (5.7%)。合并后该类球的使用占比仍下降，但这只是口径稳健性核对，不能证明两边每一球属于同一种球，也不能据此

作因果解释。NPB 的 xPV/100 与 MLB 的 Run Value/100 定义不同，只能在各自联盟内部解释，不作同尺度相减。

五、数据更新的分段门禁

`python scripts/run_pipeline.py --refresh-data` 会联网替换 raw 快照和来源清单，随后重跑分析、仓库报告与完整性检查。它不会自动修改本文件等 `.submission_revision_work/sources` 下的静态 Markdown，也不会自动改写已经生成的提交版 Word。因此，更新不能止于命令成功。

阶段	必做检查	未通过时的处理
1 确定窗口	修改配置中的截止日，说明为何更新，并保留旧版本哈希或 Git 提交	截止日和用途不清，不刷新
2 刷新 raw	显式运行 <code>--refresh-data</code> ；核对 17 项预期来源、URL、时间、哈希、Statcast 球员 ID 和日期范围	来源缺失、网页结构变化或校验失败，停止发布
3 重算与对账	完成 <code>analyze.py</code> 、 <code>build_reports.py</code> 、 <code>verify_project.py</code> 和测试；检查四项对账差值、缺失球种、zone 缺失及各指标新分母	任何差值或异常未解释，不进入文档阶段
4 人工更新静态材料	逐项修改本稿的截止日、样本数、149/288 等分母、K-BB 落盘位置、CH+FS 核对、NPB ERA 常数和版本号，再重新生成 Word	不允许只替换正文中的少数赛季数字
5 提交验收	比较新旧结果，检查表图与分页，确认 Word、仓库输出和来源清单使用同一窗口	三处版本不一致，不替换提交包

底稿中的任何数字都应能沿“提交文字—处理输出—脚本字段—原始快照—来源清单”反向追溯。这个链条闭合后，底稿 02 才可以随提交材料一并交付。