

底稿 04 复现与交付核查说明

环境、冻结复现、证据分层与提交验收

杨炎新 (3230102355) | 数据截止: 2026 年 8 月 12 日 | 最终版本: 9c8033d

一、说明范围

本说明只回答两件事: 冻结项目怎样运行, 以及交付物怎样验收。数据来源、指标口径和四项对账的具体数值见底稿 02; 研究判断如何经过证据检验和反证而改变见底稿 03。本稿不重复分析结论和推断限制, 以免同一事实分散在多份材料中后出现版本差异。

本轮对应仓库 commit 为 9c8033d181b5077e29aa67c8606e49f8db4ac842。核查时本地 main、origin/main 与该 commit 一致, 工作区无未提交改动; GitHub Actions run 31870800186 已在同一 commit 上运行成功。远程 CI 证明的是仓库冻结流程和测试在规定环境中通过, 不代替最终提交 Word 的内容、页数和签章检查。

二、环境建立与冻结复现

参考验收环境为 Windows、Python 3.12.13。requirements.txt 已固定 numpy 2.3.5、pandas 3.0.1、Pillow 12.3.0、python-docx 1.2.0、lxml 6.1.1 和 pypdf 6.10.0。进入 MLB-Analytics 目录后, 先建立独立环境:

```
py -3.12 -m venv .venv
```

```
.\.venv\Scripts\python.exe -m pip install --upgrade pip
```

```
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
```

冻结复现不访问网络, 也不覆盖 data/raw。执行:

```
.\.venv\Scripts\python.exe scripts\run_pipeline.py
```

```
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

第一条命令依次运行 analyze.py、build_reports.py 和 verify_project.py; 第二条命令运行测试。当前冻结版本中, 流水线返回 0, 12 项测试通过, qa/integrity_report.json 中的 overall_pass 为 true。

这里需要区分“来源档案”和“本次计算输入”。data/raw/source_manifest.csv 与.json 登记 17 份原始来源快照; 校验程序会逐项核对文件字节数和精确 SHA-256, 并检查两份 manifest 记录一致。这 17 份文件共同构成来源留档, 但不等于 analyze.py 会逐一读取它们。

当前分析脚本直接读取 4 份 raw 文件:

- mlb_statsapi_game_log_2026.json;
- statcast_imai_2026.csv;
- savant_pitch_arsenal_stats_2026.csv;
- savant_expected_stats_pitchers_2026.csv。

脚本还直接依赖两份已经冻结的 NPB 处理表:

- data/processed/npb_basement_imai_advanced_pitching_2023_2025.csv;
- data/processed/npb_basement_imai_pitch_values_2023_2025.csv。

因此，现有离线流程能够从上述输入重算 MLB 分析表、图和报告，但不是把 17 份 raw 全部重新加工成所有 processed 文件的完整链条。复现时应保留仓库中的冻结 processed 目录；17 份 raw 的作用是来源追溯、哈希核查以及今后刷新时的留档。

三、刷新数据时的分段检查

python scripts/run_pipeline.py --refresh-data 会依次联网抓取、分析、构建报告并校验，但它不能单独作为“新版本已经完成”的凭据。原因是 build_reports.py 读取的是 reports/sources/formal_manuscript.md 和 reports/sources/full_analysis_draft.md 两份静态文字源；数据更新后，正文中的数字不会自动改写。为了避免“表已更新、文字仍是旧值”，建立新冻结点时按下列顺序执行：

1. 新建分支或工作副本，先在 config/analysis.json 写明新的截止日期与球员标识。
2. 运行 python scripts/fetch_data.py --refresh-data，保存新 raw 和来源 manifest。
3. 检查来源 URL、抓取时间、球员 ID、文件字节数、行数和 SHA-256，确认下载窗口没有混入旧文件。
4. 运行 python scripts/analyze.py，再逐项查看 data/processed 和 outputs/figures 的差异。
5. 根据新结果人工更新两份报告 Markdown，逐一核对标题、摘要、正文、表格和图注中的核心数字。
6. 运行 python scripts/build_reports.py 生成仓库公开 Word。
7. 运行 python scripts/verify_project.py 和全部单元测试；任何一项失败都停止发布。
8. 另行渲染 Word，逐页检查截断、重叠、表图清晰度、页码和孤立标题。
9. 只有上述检查全部完成，才更新截止日、清单和版本号并提交新的冻结 commit。

这样把“抓取—计算—文字更新—自动校验—视觉验收”分开留痕，能够明确错误发生在哪一段，也避免把一次能运行的命令误当成完整交付。

四、自动校验能证明什么

自动校验的范围需要按脚本实际能力解释。

第一，公开范围隐私扫描本轮共读取 24 份可扫描文件，只匹配邮箱、中国大陆手机号、10 位数字学号和 C:\Users\...本机路径四类模式。对于 DOCX，程序只读取 word/document.xml 和 docProps/core.xml，不覆盖页眉、批注、嵌入媒体等全部部件，也不识别人名。因此准确结论是“在规定的 24 份文件和四类规则中未发现匹配项”；姓名、单位、学号与签章位置仍需人工核对。

第二，qa/artifact_manifest.csv 当前登记 45 项受控产物，并不是全仓库文件清单。其范围包括配置、研究记录、processed 数据、最终图、报告文本与公开 Word、脚本、测试、工作流以及指定根文件；data/raw、本地渲染目录、缓存和若干临时 QA 文件不在其中。清单也采用三种摘要口径：文本先统一换行为 LF 后计算 text-lf-sha256-v1，DOCX 按压缩包成员名称和内容计算 zip-content-sha256-v1 并忽略 ZIP 时间戳，其余二进制才使用精确文件字节的 file-sha256-v1。所以 45 项中的 sha256 字段不能一概解释为原文件逐字节哈希。raw 的精确哈希以来源 manifest 为准，最终提交 Word 的精确文件 SHA-256 以提交目录中的提交文件清单_SHA256.txt 为准。

第三，仓库默认不保存 `qa/rendered` 和 `qa/local_visual_report.json` 等本地渲染缓存。`clean clone` 可通过冻结流水线，但直接运行 `python scripts/verify_project.py --require-visual` 时没有这些 PDF，不能得到可提交状态。仓库中的 `qa/visual_review_receipt.json` 记录过一次 LibreOffice 26.2.5.2、150 dpi 的人工逐页检查：两页决策稿 2 页，仓库版完整分析底稿 10 页。该收据虽然写有 DOCX 和 PDF 哈希，但当前校验脚本只检查 PDF 能否读取、页数是否满足规则，以及收据状态是否为 `reviewed`，不会把收据哈希与当前文件重新比对。因此它是一份当次本地人工检查记录，不是与当前文件自动绑定的密码学门禁。

五、三类证据与验收责任

证据类别	核查对象	核查方式	当前结果	适用边界
仓库自动证据	17 份 raw 来源档案	字节数、精确 SHA-256 及 CSV/JSON manifest 一致性	通过	证明档案未变，不表示 17 份均被分析脚本读取
仓库自动证据	数据、核心指标与公开 Word 结构	四项数据对账、冻结数字断言、A4/字体/图片等结构检查	通过；详细对账见底稿 02	结构通过不等于已逐页看过版面
仓库自动证据	流程与测试	离线流水线、12 项测试、Windows 远程 CI	通过	只对应 commit 9c8033d
仓库自动证据	公开范围隐私与 45 项产物	四类正则扫描；按 <code>digest_kind</code> 生成确定顺序清单	通过	不扫描人名，不是全仓库逐字节清单
本地人工视觉证据	仓库两份公开 Word	LibreOffice 渲染为 PDF/PNG 后逐页查看并留收据	2 页和 10 页已检查	<code>clean clone</code> 无缓存；脚本不校验收据哈希绑定
最终提交证据	本次五份 MLB 提交 Word	Microsoft Word 原生打开、渲染并逐页检查；另记页数和文件 SHA-256	由提交包清单记录	与仓库公开 Word 的 LibreOffice 收据分开管理

默认运行 `verify_project.py` 后，`overall_pass=true` 而 `submission_ready=false` 是预期状态：前者表示离线数据、代码和文档结构门禁通过，后者还要求本机已具备渲染文件和明确的人工审阅记录。不能为了得到 `submission_ready=true` 而复制旧缓存或只补写一条“已审阅”状态。

六、最终交付检查

正式提交前按以下顺序收口：先确认冻结 `commit` 和数据截止日；再运行离线流水线与 12 项测试；随后在 Microsoft Word 中打开五份提交材料，逐页检查截断、重叠、异常空白、表图可读性、页码和孤立标题；最后人工核对姓名、学号、单位、日期、需签字盖章的位置。学校表单或单位签章属于人工责任，不由代码自动填写或推断。

按“蒋总两页、底稿 01—04”顺序，页数为 2、8、4、3、3 页；精确 SHA-256 见同目录清单，任何改动后须重新逐页检查并重算清单。