

底稿 04 复现与交付核查说明

冻结数据、自动校验、逐页检查与工具记录

项目：MLB-Analytics | 数据截止：2026 年 8 月 12 日 | 最终版本：9c8033d

一、离线复现

项目默认读取 data/raw 中的 17 份冻结快照，不主动访问网络。环境为 Python 3.12；主要依赖固定在 requirements.txt，包括 numpy 2.3.5、pandas 3.0.1、python-docx 1.2.0、lxml 6.1.1 和 pypdf 6.10.0。

进入 MLB-Analytics 目录后运行：

```
python scripts/run_pipeline.py
```

该命令依次完成分析、报告生成和自动校验。单元测试另行运行：

```
python -m unittest discover -s tests -v
```

只有需要建立新的赛季窗口时才运行 python scripts/run_pipeline.py --refresh-data。联网刷新会改变下载时间和网页内容，因此必须同时更新截止日、来源清单、处理表和报告，不能继续引用旧窗口。

二、自动校验状态

截至最终 commit 9c8033d，本地 main 与 origin/main 一致；GitHub Actions run 31870800186 成功。qa/integrity_report.json 记录默认离线自动结果，严格视觉结果写入 qa/local_visual_report.json；两类结果的职责分开。核查摘要如下：

检查项	对象	状态
来源哈希	17 份原始快照与 manifest 逐字节比较	通过
数据对账	1,240 球、80K、42BB、17 场	四项差值 0
核心结果	冻结数字断言	通过
公开 Word 结构	A4、标题、字体、朴素样式和嵌图；正式稿首段加粗	通过
公开文件隐私	24 份文件扫描姓名、学号等信息	未发现
产物清单	45 项、顺序确定、无缓存路径泄漏	通过
单元测试	离线流程、完整性和报告结构	12 项通过
远程 CI	Windows 下离线重建与 byte-stable 检查	通过

两份仓库公开 Word 使用 LibreOffice 26.2.5.2 渲染为 150 dpi 逐页图：课程正式稿 2 页，完整分析底稿 10 页。逐页检查未发现截断、重叠、乱码和异常分页；曾出现的来源孤页已消除。

qa/visual_review_receipt.json 记录页数、文件哈希、审阅时间和检查项；运行 python scripts/verify_project.py --require-visual 后，render_verification=passed、manual_visual_qa=reviewed、submission_ready=true。

三、推断限制

- Zone%按 Statcast zone 字段 1—9 计算，不代表具体位置质量。
- 先发与牛棚不是随机实验；23 个牛棚打席不能给出角色因果。
- MLB 变速球只有 29 球，62.5% Whiff 来自 5/8 次挥棒，不能外推长期效果。
- NPB 与 MLB 环境和价值模型不同，NPB xPV/100 不与 MLB Run Value/100 直接相减。
- 面对打线轮次先筛选先发，再直接使用 n_thruorder_pitcher，只作描述。
- 医疗、握法和动作信息不在公开数据中；统计阈值不能替代球队评估。

四、生成式工具记录

本次课程允许使用生成式工具，并要求保留过程。工具参与了公开资料抓取、代码编写、计算、初稿分析和 Word 排版；模型输出本身没有被当作事实来源。数值证据回到冻结快照、处理表或正式网页，观察性分组没有改写成因果，未取得的球队内部信息没有补写。

最初任务及后续提示记录在 docs/research/ai_prompt_log.md，判断变化记录在 docs/research/hypothesis_log.md 与 docs/research/analysis_cycle_results.md。本轮成稿逐项核对了分母、样本量、来源、观察性边界和建议；最终是否提交仍由提交者阅读确认并承担责任。

步骤	关键提示/任务	工具阶段总结	最终复核重点
1 选题	阅读课程 PDF，依据题目、指标和数据源确定选题	选择题目二，收敛为控球、球种与角色决策	题目与课程要求是否一致
2 授权研究	贯通资源获取、分析、问题发现、结论与迭代全流程	采用公开数据，保存快照、代码、哈希、假设和底稿	是否存在未取得却被写入的事实
3 数据冻结	建立项目并绑定 GitHub，阶段性推送	留存 MLB、Savant、NPB 与报道共 17 份快照	URL、截止日、SHA-256
4 初步诊断	检查高 ERA 是否代表球威不足	K%保持，BB%、Zone 与首球更值得优先处理	分子、分母和联盟口径
5 球种修正	判断是否需要开发第三球种	改为恢复 NPB 已有变速球；四缝线风险集中左打	29 球小样本与速度差逻辑
6 角色反证	判断牛棚是否已经解决问题	23 打席只能支持短期校准，不给出角色因果	Wilson 区间、混杂因素和第三轮
7 成稿检查	形成两页稿、完整底稿和复现项目	自动校验与人工视觉分开记录	字体、页数、截断和结论措辞

上表是提示和阶段输出的索引，不替代原始日志。完整文本随仓库提交，便于老师查看分析为何改变。

五、最终 Word 检查

检查项	通过标准	本轮状态
课程正式稿	A4 不超过 2 页；9pt 微软雅黑；首段论点加粗	2 页，通过
五份 MLB 文档	无截断、重叠、空白页和孤立标题	2、7、3、2、3 页，逐页通过
事实与边界	核心数字可回到 CSV；小样本和观察性措辞准确	通过
身份与版本	姓名、学号、截止日、仓库 commit 一致	通过；仓库版本 9c8033d
文件完整性	文件可打开；记录页数、SHA-256 和修改时间	通过；校验值见同目录清单

五份 MLB 文档已逐页检查，课程正式稿和完整底稿的严格仓库门禁也已通过。学校纸质表格的签名和单位盖章不属于代码校验范围，需要提交人另行办理。