

第1周实习记录

学生	杨炎新	学号	3230102355
实习单位	上海思搏动态智能科技有限公司	记录主题	第1周：选题与基础学习

说明：以下内容按项目实际推进顺序整理，具体日期以会议材料和实验记录为准。

一、阶段工作概况

本周先阅读课程材料，并开始确定数据分析题目。我起初想直接比较今井达也在NPB和MLB的ERA、三振、保送等成绩，再根据差异提出调整建议。查完首批资料后，我发现这个思路太宽，最后很可能只得到“表现变差”这样的结论，既解释不了原因，也无法回答他应该继续先发还是转入牛棚。

因此，我把题目收窄为一个具体的决策问题：**今井达也目前的困难主要来自球威、控球、球种结构还是先发负荷，球队应依据什么条件让他重返先发轮值？**我把五个待检验判断写进研究假设记录：三振和挥空能力是否保留；保送增加是否与进区能力有关；四缝线和滑球是否过于集中；两次牛棚表现能否支持角色变化；第三球种在NPB时期是否已有稳定基础。此后每张表都对应一个待回答的问题，避免先出结果再寻找解释。

二、资料搜集与口径设计

确定问题后，我先检查所需数据能否取得。MLB部分使用StatsAPI比赛日志和Baseball Savant逐球数据：前者用于核对比赛结果，后者提供球种、球数、位置和挥棒等细节。NPB部分使用官方球员页和NPB Basement，补充今井2018—2025年的职业轨迹与球种变化。新闻报道只用于了解转入牛棚和伤情背景，不作为数值依据。

整理指标时，我很快遇到一个问题：名称相同的指标，计算口径未必相同。逐球、打席和比赛日志属于不同分析层级，NPB的 $xPV/100$ 也不能直接与MLB的 $Run\ Value/100$ 作差。为避免后面混用，我先建立指标表，逐项记录分子、分母、数值方向和适用范围。ERA、K%和BB%用于描述结果；Zone%、首球好球率、Whiff%和Chase%用于观察过程；球种使用率和左右打拆分则用来支持具体的配球建议。

三、港科大暑研进展

同期，我在香港科技大学 IEDA 系开展的大模型对齐暑研从 RLHF 和 DPO 基础入手。我先梳理“偏好数据—奖励模型—策略更新”的基本流程，再理解 DPO 为何能够绕开显式奖励模型。阅读中，我重点关注 reward realizability 和 policy realizability，因为奖励模型即使能够较好拟合偏好标签，也未必能在受限策略类中带来最好的策略。

7月14日，我以《Preference Learning: RLHF & DPO》为题参加组会汇报。准备过程中，我尝试把 Smart Predict-then-Optimize 的想法迁移到大模型对齐：预测误差较小，并不一定意味着下游决策损失也小，因此奖励模型不能只按偏好拟合效果评价。汇报后，我将研究问题进一步收窄为“在可实现的 reward class 中，哪一种奖励能够带来更高的 policy utility”，这也成为 Prospective Reward Modeling 的出发点。

四、问题与调整

回头看，本周最大的失误是过早寻找结论。只看几项赛季数据，很容易先入为主地归因于“联盟强度提高”或“球威不足”。发现这一点后，我暂停结果比较，先写清研究对象、数据截止日、各指标分母，以及哪些证据会推翻原来的猜测。例如，只有 K% 和 Whiff% 同时明显下降时，才更支持球威整体退化；牛棚样本很少时，也不能把短期改善直接解释为角色转换的效果。

本周没有急着制作大量图表，而是先把研究对象、五项假设、指标口径和来源框架定下来。回头检查时，我能明确说出什么证据支持判断、什么证据会推翻判断，这比过早给出结论更重要。

五、阶段产出与后续安排

- 确定研究问题，并列出五项待检验判断及其反证条件。
- 建立 MLB、NPB 公开数据来源框架和第一版指标字典。
- 完成 RLHF、DPO 与奖励错设问题的基础阅读，并进行第一次暑研汇报。
- 下一周重点冻结原始数据版本，核对逐球数据与官方比赛日志；暑研继续推导 reward utility 和 policy regret。